

RÉPUBLIQUE DU CAMEROUN

Paix - Travail - Patrie

UNIVERSITÉ DE YAOUNDÉ I

FACULTÉ DES SCIENCES

DÉPARTEMENT D'INFORMATIQUE



REPUBLIC OF CAMEROON

Peace - Work - Fatherland

UNIVERSITY OF YAOUNDE I

FACULTY OF SCIENCE

DEPARTMENT OF COMPUTER SCIENCE

COMPOSITION DES METHODES HRMS ET RMN PAR APPRENTISSAGE ENSEMBLISTE POUR L'IDENTIFICATION DES RESEAUX MOLECULAIRES

En vue de l'obtention du diplôme de Master Recherche en Informatique

Option :

Science des données

Présenté par :

MBE MBE MINDJANA LOIC HENRI

Matricule :

18T2603

Supervisé par :

Pr. WAFFO TEGUO Pierre

Pr. MELATAGIA YONTA Paulin

Année académique 2022 / 2023



Université de Yaoundé 1
Département d'Informatique

COMPOSITION DES METHODES HRMS ET RMN PAR APPRENTISSAGE ENSEMBLISTE POUR L'IDENTIFICATION DES RESEAUX MOLECULAIRES

Présenté par : MBE MBE MINDJANA LOIC HENRI

Matricule :
18T2603

Supervisé par :
Pr. WAFFO TEGUO Pierre
Pr. MELATAGIA YONTA Paulin

Année académique 2022/ 2023

DÉDICACES

Je dédie ce mémoire à ma présente et future famille.

REMERCIEMENTS

Au terme de ce travail, qui est le fruit de beaucoup d'efforts, de sacrifices et de grâces, je voudrais exprimer ma profonde gratitude à Dieu et aux personnes dont les contributions ont été importantes et appréciées.

En premier lieu, et à juste titre, j'exprime ma reconnaissance envers mon encadreur Dr. MELATAGIA YONTA Paulin pour m'avoir permis de travailler avec lui et de toucher à ce domaine passionnant qui m'était inconnu. Ce fut un privilège pour moi de travailler avec lui. Son esprit d'honnêteté scientifique, sa planification du travail et surtout sa rigueur scientifique et de vie, sont autant de qualités que je souhaite hériter de lui.

Je remercie également le Pr. WAFFO TEGUO Pierre responsable du Laboratoire de Pharmacognosie UFR des sciences pharmaceutiques de l'Université de Bordeaux, pour sa disponibilité et ses orientations sur le domaine de la biologie appliqué à la découverte des médicaments. Grâce à nos échanges j'ai pu avoir une base importante sur le domaine thématique.

Je remercie l'Université de Yaoundé I, notamment le Département d'Informatique, pour la qualité des enseignements dispensés tout au long de notre parcours académique.

J'exprime ma profonde gratitude à mes proches TCHENEGHON Herman, TCHAHEU Dimitri et ANANJOU Stela, qui m'ont permis grâce à leurs interrogations de voir plus clair sur des points clés de mon thème.

Je n'oublie pas un de nos enseignants, le Dr. NZEKON Armel qui m'a permis de vraiment débloquer ma compréhension de points clés de mon thème, lors de nos présentations grâce à ces multiples interrogations.

Je tiens également à remercier Msr OTTOU OTTOU Prosper Directeur de la cellule informatique du BUNEC pour m'avoir épauler.

Enfin, je remercie mes parents, plus particulièrement Mme KOUAKAM YVETTE (Ma'a Yvette) qui est la base de tout, Msr TSEMO Hervé (Pa'a Hervé), Msr NGHEMCHE Sylvain (Pa'a Sylvain), Mme YOUOGO Adéline (Ma Adéline), Mme KENMENGNE Chimène (Ma'a Chimène) et Mme NINGHUEM Nadège (Ma'a Nadège), Msr TAMTCHOUM Donald (Pa'a Donald), Mme DAYO Jaqueline (Mawouo).

RÉSUMÉ

Dans le domaine de la découverte de médicaments basée sur les produits naturels, trouver les principes actifs contenus dans ses produits est une tâche ardue. Cette tâche basée sur des expérimentations faites en laboratoire, a conduit à l'utilisation de techniques de spectrométrie MS et MRN, pour obtenir des représentations exploitables pour la recherche d'un ensemble de molécules étant déjà identifiées et la construction d'un réseau de cet ensemble de molécules. Ce réseau obtainable en utilisant des méthodes tels que GNPS et MADByTE prenant en entrée des spectres MS et RMN respectivement, permet de regrouper des molécules similaires avec les liaisons de correspondance, qui après analyse oriente les expérimentations chimiques d'identification des molécules. Cependant aucune méthode existante n'exploite la complémentarité d'informations entre les spectres MS et RMN. Cette étude vise à l'exploiter en combinant grâce à l'apprentissage par ensemble les méthodes GNPS, MADByTE et les algorithmes de clustering multi-vues MCLES ou MVGL qui tiennent compte non seulement de la complémentarité mais aussi du consensus entre plusieurs représentations d'observations. Pour extraire les clusters contenus dans les réseaux issues de GNPS et de MADByTE pour les introduire dans les processus d'apprentissage, nous utilisons l'algorithme DBSCAN en définissant le voisinage d'une molécule pour chacun de leurs réseaux. Pour l'approche utilisant Bagging nous obtenons sur la dataset MSRC-V1 les meilleures performances de constructions de clusters avec MCLES comme weak-learner, affichant 80.1% d'exactitude, 74.3% d'information mutuelle normalisée et 81.1% de pureté.

Mots clés : apprentissage par ensemble, clustering multivues, spectrométrie, réseau moléculaire, découverte de médicaments.

ABSTRACT

In the field of natural product-based drug discovery, identifying the active compounds within these products is a challenging task. Scientists rely on lab experiments and use techniques like mass spectrometry (MS) and nuclear magnetic resonance (NMR) to get usable representations of molecules that have already been identified. These representations help build molecular networks. Tools like GNPS and MADByTE, which process MS and NMR spectra respectively, are used to build these networks by grouping similar molecules and showing how they are connected. These connections guide further chemical experiments to identify unknown compounds. However, current methods do not take advantage of the complementary information provided by MS and NMR together. This study explores how ensemble learning can help, by combining GNPS, MADByTE, and multi-view clustering algorithms like MCLES or MVGL. These algorithms can learn from multiple data views while considering both complementary features and consensus patterns. To extract clusters from the GNPS and MADByTE networks for the learning process, we use the DBSCAN algorithm, defining molecular neighborhoods in each network. Using a Bagging-based approach on the MSRC-V1 dataset, we achieved strong results with MCLES as the weak-learner : 80.1% accuracy, 74.3% normalized mutual information, and 81.1% purity in cluster formation.

Keywords : ensemble learning, multi-view clustering, spectrometry, molecular network, drug discovery.

TABLE DES MATIÈRES

1	Introduction Générale	1
1.1	Contexte et problème	1
1.2	Question de recherche	2
1.3	Généralités	2
1.3.1	Atome et Molécule	2
1.3.2	Spectrométrie	3
1.3.3	Déréplication et réseau moléculaire	5
1.4	Plan du mémoire	7
2	État de l'art	8
2.1	Clustering	8
2.1.1	Density-Based Spatial Clustering of Applications with Noise (DBSCAN) . .	9
2.1.2	Structural Clustering Algorithm for Networks (SCAN)	9
2.1.3	Network Space - Density-Based Spatial Clustering of Applications with Noise (NS-DBSCAN)	10
2.2	Clustering Multi-vues	10
2.2.1	Algorithmes sans apprentissage de représentation	11
2.2.2	Algorithmes basés sur l'apprentissage de représentation	13
2.2.3	Comparaison des algorithmes de clustering multi-vues	14
2.2.4	Multi-View Clustering in Latent Embedding Space (MCLES)	16
2.2.5	Multi-View Graph Learning (MVGL)	19
2.3	Algorithmes d'ensemble de clustering	22
2.3.1	Algorithmes de correspondance forte	22
2.3.2	Algorithmes de correspondance légère	22
2.3.3	Algorithmes basés sur les observations	23
2.3.4	Algorithmes basés sur les clusters	23
2.3.5	Algorithmes basés sur les clusters et les observations	24
2.3.6	Comparaison des algorithmes d'ensemble de clustering	24
2.3.7	Adaptive Clustering Ensemble (ACE)	25
2.3.8	Meta-CLustering Algorithm (MCLA)	27

3	Algorithmes proposés et expérimentations	29
3.1	Algorithmes proposés	29
3.1.1	Introduction	29
3.1.2	Méthode de type Bagging	29
3.1.3	Méthode de type Boosting	31
3.1.4	Conclusion	32
3.2	Expérimentations et Résultats	33
3.2.1	Jeu de données	33
3.2.2	Métriques d'évaluation	33
3.2.3	Protocole expérimentale	34
3.2.4	Résultats	34
4	Conclusion Générale	42
	Bibliographie	43

TABLE DES FIGURES

1.1	Spectre MS du Glycérol	3
1.2	Spectre RMN du Glycérol observant les atomes d'hydrogène	4
1.3	Processus de GNPS [1]	6
1.4	Processus de MADByTE	7
2.1	Types clés d'observations de DBSCAN	9
2.2	Taxonomie des algorithmes de clustering multi-vues [2]	11
2.3	Processus général des algorithmes de clustering multi-vues de co-formation [3]	11
2.4	Processus général des algorithmes de clustering multi-vues multi-noyaux [3]	12
2.5	Processus général des algorithmes de clustering multi-vues basés sur les graphes [2] .	13
2.6	Processus général des algorithmes de clustering multi-vues de sous-espaces [3]	14
2.7	Processus général des algorithmes de clustering multi-vues d'apprentissage profond de représentation [2]	14
2.8	Processus de l'algorithme MCLES	17
2.9	Workflow de l'algorithme MVGL [4]	20
2.10	Processus général des algorithmes de correspondance forte	22
2.11	Processus de l'algorithme ACE [5]	26
3.1	Processus de l'approche de type Bagging	30
3.2	Processus de l'approche de type Boosting	32
3.3	Graphes de l'exactitude pour l'approche de type Bagging avec MCLES	35
3.4	Graphes de l'information mutuelle normalisée pour la méthode de type Bagging avec MCLES	35
3.5	Graphes de la pureté pour la méthode de type Bagging avec MCLES	36
3.6	Graphes de l'exactitude pour la méthode de type Bagging avec MVGL	38
3.7	Graphes de l'information mutuelle normalisée pour la méthode de type Bagging avec MVGL	38
3.8	Graphes de la pureté pour la méthode de type Bagging avec MVGL	39
3.9	Corrélations entre métriques pour la méthode de type Bagging	41

LISTE DES TABLEAUX

2.1	Tableau de comparaison des algorithmes de clustering multi-vues	15
2.2	Tableau de comparaison des algorithmes d'ensemble de clustering	24
3.1	Tableau croisé de l'exactitude pour la méthode de type Bagging avec MCLES . . .	36
3.2	Tableau croisé de l'information mutuelle normalisée pour la méthode de type Bagging avec MCLES	37
3.3	Tableau croisé de la pureté pour la méthode de type Bagging avec MCLES	37
3.4	Tableau croisé de l'exactitude pour la méthode de type Bagging avec MVGL	39
3.5	Tableau croisé de l'information mutuelle normalisée pour la méthode de type Bagging avec MVGL	40
3.6	Tableau croisé de la pureté pour la méthode de type Bagging avec MVGL	40
3.7	Tableau des valeurs par défaut des paramètres de la méthode de type Bagging . . .	40
3.8	Tableau de comparaison des performances	41

LISTE DES ABRÉVIATIONS

- ACE** Adaptive Clustering Ensemble. v, 23, 25, 28
- Bagging** Bootstrap Aggregating. 29
- CAH** Classification Ascendante Hiérarchique. 8, 11, 23
- CDH** Classification Descendante Hiérarchique. 8, 23
- CSPA** Cluster-based Similarity Partitioning Algorithm. 23
- DBSCAN** Density-Based Spatial Clustering of Applications with Noise. v, 8, 9, 28, 29
- EM** Expectation - Maximisation. 11
- GMM** Gaussian Mixture Model. 8
- GNPS** Global Natural Product Social. 5, 29
- HRMS** High Resolution Mass Spectrometry. 4
- HSQC** Heteronuclear single quantum coherence spectroscopy. 5, 6
- INCHI** International Chemical Identifier. 3
- IR** Infra Rouge. 3
- MADByTE** Metabolomics And Dereplication By Two-dimensional Experiments. 5, 6, 29
- MCLA** Meta-CLustering Algorithm. v, 23, 25, 27, 28
- MCLES** Multi-View Clustering in Latent Embedding Space. v, 14, 16, 18, 28, 31
- MS** Mass Spectrometry. 3, 5, 30, 33
- MVGL** Multi-View Graph Learning. v, 13, 16, 19, 28, 31

NMI Normalized Mutual Information. 33

NS-DBSCAN Network Space - Density-Based Spatial Clustering of Applications with Noise. v, 8, 10

RMN Resonance Magnetique Nucléaire. 3–5, 30, 33

SCAN Structural Clustering Algorithm for Networks. v, 8, 9, 28

SMILE Simplified Molecular Input Line Entry System. 3

TOCSY Total Correlation Spectroscopy. 5, 6

CHAPITRE 1

INTRODUCTION GÉNÉRALE

1.1 Contexte et problème

Depuis toujours l'homme a mis au point des techniques et méthodes pour exploiter les plantes afin de produire des médicaments. De nos jours pour prévenir des maladies ou en guérir, nous utilisons des médicaments spécifiques obtenus en laboratoire par expérimentations d'essais-erreurs sur ces produits naturels, pour en déceler et en extirper les principes actifs qui leur permettent d'avoir des effets sur les parasites ou virus qui conduisent à ces maladies. On peut parler de l'Artémisine contenu dans l'*Artemisia* qui réagit nocivement sur le plasmodium, qui est la source du paludisme, maladie la plus fréquente à l'heure actuelle dans nos localités.

L'avenue d'Internet et des nouvelles technologies physico-chimiques, ont permis de voir affluer de grande quantité de données chimiques et biologiques de principes actifs et autres molécules, qui ont pu pour certaines, être accessibles au grand public. Cette grande quantité de données contenus dans des bases de données telque MedChem¹, NIST², MetaSpace³, MassBank⁴, ReSpect⁵, ont permis de voir émerger plusieurs outils et techniques afin de les exploiter pour optimiser les processus expérimentaux. On peut citer des méthodes d'apprentissage artificielle [6] (Machin Learning) qui visent, à identifier les molécules réagissant sur les parasites de maladies spécifiques en utilisant des modèles de classification, à prédire les fonctions biologiques de molécules tels que la bio-activité par rapport à un ensemble de parasites ou molécules spécifiques grâce à des modèles de prédiction, à générer des structures de molécules qui pourraient être des constituants de principes actifs contre des parasites donnés grâce à des modèles de génération. On retrouve aussi des outils qui visent à exploiter plus généralement les données par exploration, à savoir Sherlock [7], LOTUS [8], ENPKG [9] qui permettent l'élucidation de structures de molécules bioactives ou non, qui utilisent comme représentations des molécules les spectres MS et RMN qui contiennent des informations obtenues de leurs structures dans des états données (ionisation, excitation).

Dans le cadre de la recherche de molécules basée sur les produits naturelles, les biologistes utilisent de nos jours des outils tels que GNPS [1] et MADByTE [10], qui exploitent les spectres MS ou RMN des molécules à explorer. Ils ont pour but de produire des réseaux ou encore carte

1. Site officiel de MedChem <https://www.medchem.be/>

2. Site officiel de NIST <https://www.nist.gov/srd/nist-standard-reference-database-1a>

3. Site officiel de MetaSpace <https://metaspace2020.eu/>

4. Site officiel de MASSBANK <https://massbank.eu/MassBank/>

5. Site officiel de ReSpect https://respectem.com/?page_id=42

de ces molécules qui regroupent celles qui sont similaires entre eux, contenant leurs spectres et leurs structures (pour celles qui sont identifiées) en métadonnées. Ces réseaux appelés réseaux moléculaires sont grandement utiles car permettent de détecter des similitudes entre molécules pour orienter les expérimentations d’essais-erreurs qui sont longues. Néanmoins malgré le fait que l’on sache que les spectres MS et RMN contiennent des informations complémentaires issus des constituants des molécules, à notre connaissance aucune méthode existante ne permet de les exploiter simultanément, que ce soit les modèles de prédiction, classification et de génération.

1.2 Question de recherche

L’objectif du travail de recherche effectué dans le cadre de ce mémoire est de répondre à la question suivante : Comment exploiter la complémentarité des spectres MS et RMN dans le but d’orienter et d’accélérer les expérimentations de découverte de molécules, basée sur les produits naturels, qui conduisent à identifier des réseaux moléculaires ?

Pour répondre à cette question, nous proposons deux méthodes basées sur les techniques d’apprentissage par ensemble Bagging et Boosting. L’idée principale de ces méthodes est d’utiliser GNPS et MADByTE (qui construisent des graphes de molécules identifiées ou pas sur la base de spectres MS et RMN respectivement), conjointement avec des algorithmes de clustering multi-vues MCLES ou MVGL. Pour introduire GNPS et MADByTE dans les apprentissages, nous utilisons l’algorithme DBSCAN qui va extraire les clusters contenus dans les réseaux moléculaires fournis par ces derniers, en définissant le voisinage d’une molécule dans un réseau.

1.3 Généralités

1.3.1 Atome et Molécule

Tout élément dans la nature est constitué de particules de très petites tailles qu’on appelle **atomes**. On peut citer les atomes de produits organiques suivants : le carbone (C), l’hydrogène (H), l’oxygène (O) et l’azote (N). Ces atomes associés ou encore liés permettent d’avoir des **structures** dite de simple à complexe (grâce à des liaisons simples, doubles, triples, cycles), représentant des matières qu’on appelle des **molécules**. Ce sont donc ces molécules de taille éventuellement grande ou petite qui forment la matière. Il existe de ce fait des molécules capables de guérir des maladies, par le biais de leur capacité d’initier des suites de réactions. On appelle ces molécules des molécules bio-actives ; “bio” parce qu’elles participent aux réactions internes (métabolisme) et à l’entretien d’un organisme vivant et “actives” pour leur capacité à déclencher des réactions chimiques sur d’autres molécules précises.

Dans le cadre des recherches visant à concevoir des médicaments en s’appuyant sur les produits naturels, les biologistes réalisent un ensemble d’étapes expérimentales [11] sur pour identifier les molécules bio-actives y contenus. On peut citer comme exemple l’Artemisia qui permet d’agir nocivement sur le plasmodium (parasite causant le paludisme), ou encore l’hoffe (l’igname bulbifère) qui a des propriétés de défense (anti oxydantes). Ces étapes bien qu’elles ont permis de trouver des ensembles de molécules bio-actives, dégradent ou détruisent malheureusement les molécules qui entrent dans le processus. De plus, ils détruisent parfois des synergies entre ces molécules qui permettaient d’observer leurs activités.

Pour réduire ces effets, les biologistes exploitent les molécules déjà **identifiées** en laboratoire, pour faciliter l’identification de celles inconnues. Ils sauvegardent ainsi dans des bases de




FIGURE 1.1 – Spectre MS du Glycérol

données spécifiques, leurs métadonnées constituées de leurs structures contenues dans leurs représentations SMILE et INCHI, avec d'autres à savoir leurs spectres MS(Mass Spectrometry) ou RMN(Résonance Magnétique Nucléaire). Les spectres MS et RMN (et autres), ne sont pas utilisés de façon anodine car en pratique il y'a plus de difficulté à obtenir des structures de molécules par expérimentations, que d'avoir leurs spectres. D'où l'utilisation de techniques de spectrométrie.

1.3.2 Spectrométrie

La **spectrométrie** est une discipline qui visent à obtenir des grandeurs physiques d'éléments donnés, qui sont dans notre cas des molécules. Elle permet d'avoir par le biais de ces grandeurs, un ensemble d'informations issues des structures des molécules.

Des informations qu'on souhaite extrairent, on retrouve plusieurs types de spectrométrie à l'instar de la **spectrométrie de masse** (MS), la **spectrométrie par résonance magnétique nucléaire** (RMN) et de la spectroscopie infrarouge (IR), etc En biologie ceux qui sont les plus utilisés sont les spectrométrie de masse et par résonance magnétique nucléaire.

Spectrométrie MS

Cette méthode de spectrométrie a pour but d'extraire d'un élément chimique, la masse sur charge et l'abondance relative de ses fragments de molécules ionisés appelés couramment radicaux⁶ [12]. Ces informations constituent ce qu'on appelle un spectre de masse ou spectre MS, qu'on visualise généralement sur un graphique semblable à celui de la Figure 1.1⁷ correspondant à celui du glycérol contenu généralement dans les cirots prescrits dans des formations sanitaires.

Pour pouvoir le faire on utilise une machine spécialisée appelée spectromètre de masse qui contient généralement :

- un tube de liquide : dans lequel on introduit l'élément chimique

6. Lien du site d'explication <https://www.studysmarter.fr/resumes/physique-chimie/chimie/spectrometrie-de-masse>

7. Prise sur https://www.chemicalbook.com/SpectrumEN_56-81-5_Raman.htm




FIGURE 1.2 – Spectre RMN du Glycérol observant les atomes d’hydrogène

- un ioniseur : qui par le biais de faisceau d’électrons permet d’ioniser l’élément
- un accélérateur de particules : qui a pour but de dévier les radicaux d’un rayon de courbure qui dépend de leur masse sur charge
- un détecteur : qui permet d’évaluer ces rayons de courbure (par conséquent les masses sur charge) et d’avoir les abondances de ces radicaux (ou encore intensité)

On parle ainsi de :

- Spectrométrie de masse à haute résolution HRMS : lorsqu’on utilise des spectromètres de masse spécialisés tels que **Orbitrap**.
- Chromatographie liquide/ Spectrométrie de masse **LC/MS** : lorsqu’on utilise la technique de séparation de molécules contenues dans une solution aqueuse nommée chromatographie avant la spectrométrie de masse
- Spectrométrie MS^2 (MS/MS) : lorsqu’on utilise des spectromètres de masse qui possèdent deux étapes d’ionisation consécutives avant analyse

Spectrométrie RMN

Cette méthode de spectrométrie a plutôt pour but d’extraire d’un élément chimique, les déplacements chimiques et les intensités d’excitation que réalisent ses atomes de types spécifiques (Hydrogène, Carbone etc ...), lorsqu’il est placé dans un champ magnétique (zone de forces issues d’un aimant ou de déplacements d’électrons). Ces informations constituent ce qu’on appelle un spectre de résonance magnétique nucléaire ou encore spectre RMN, qu’on visualise généralement sur un graphique semblable à celui de la Figure 1.2⁸ étant celui du glycérol.

8. Prise sur https://www.chemicalbook.com/SpectrumEN_56-81-5_Raman.htm

Pour obtenir ces informations, on utilise un spectromètre RMN encore appelé sonde RMN, qui est un compartiment qui permet d'utiliser des champs magnétiques excitant des types d'atomes précis d'une molécule, en considérant un champ de base (celui agissant sur le Tetramethylsilane TMS).

Lorsqu'on observe 'n' types d'atomes on parle de spectrométrie 'n-RMN', par exemple pour :

- la spectrométrie **1-RMN** : on a la spectrométrie sur hydrogène (H-RMN), Spectrométrie sur carbone (C-RMN)
- la spectrométrie **2-RMN** : on a Total Correlation Spectroscopy (TOCSY) qui observe les croisements hydrogène-hydrogène), Heteronuclear single quantum coherence spectroscopy (HSQC) qui observe les croisements hydrogène-carbone

Ces techniques permettent d'avoir des informations sur des molécules sans pour autant avoir leurs structures, qui en laboratoire est un processus long surtout pour la découverte de médicaments basée sur les produits naturels. Ils sont très utiles dans ce processus car ils permettent d'éviter de réaliser des expérimentations sur des molécules déjà identifiées en observant les correspondances de spectres entre molécules. On appelle cette opération la déréplication.

1.3.3 Déréplication et réseau moléculaire

La **déréplication** est une opération qui consiste à trouver dans un ensemble de molécules, celles qui ont déjà été identifiées par correspondance de spectres par rapport à celles identifiées et sauvegardées dans des bases de données. Elle permet de réduire les expérimentations d'essais - erreurs en donnant la possibilité de se concentrer sur des molécules inconnues. Dans le but de retrouver ces molécules inconnues, on observe leurs correspondances avec ceux qui ont été identifiées pour essayer de détecter les synergies et relations qui peuvent exister entre elles.

Pour bien le visualiser, on utilise un graphe où un nœud correspond à une molécule (représentée par un spectre), avec une liaison entre deux nœuds correspondant au niveau de ressemblance (similarité) ou de différence entre eux. Il faut noter que ces nœuds ou encore sommets portent les métadonnées disponibles de leurs molécules correspondantes. On appelle ce type de graphe un **réseau moléculaire**, qui plus formellement est un graphe epsilon-voisinage, avec des sommets étant des molécules et des arêtes correspondant à la similarité ou la dissimilarité entre leurs spectres (MS ou RMN).

Plus ce réseau contient de molécules identifiées, plus on augmente les possibilités d'identifier toutes les molécules y contenues par des restrictions d'expérimentation. On parle ainsi de **réseau identifié** quand toutes les molécules y contenues sont identifiées. Cela signifie que bien construire un réseau moléculaire (par le choix de métrique et des liaisons) permet d'accélérer le processus de découverte. Des différents moyens d'en construire et du type de spectre utilisé, il existe plusieurs outils ou méthodes dont les plus communs sont Global Natural Product Social (GNPS) et Metabolomics And Dereplication By Two-dimensional Experiments (MADByTE).

Global Natural Product Social (GNPS)

GNPS [1] est une plateforme dont le processus principal prend en entrée des spectres MS de molécules pour construire le réseau moléculaire. Comme on peut le voir sur la Figure 1.3, ce processus suit plusieurs étapes :

- **Construction du template du réseau des molécules d'entrées** : cette étape a pour objectif de construire le réseau des molécules d'entrées en utilisant comme mesure de similarité le cosinus de similarité avec un seuil donné (plus de 0.63 en pratique)




FIGURE 1.3 – Processus de GNPS [1]

- **Identification des molécules par correspondance dans sa base de données** : cette étape a pour objectif de trouver les molécules d'entrées qui sont déjà dans la base de données, en faisant une recherche basée sur la correspondance de spectres utilisant le cosinus de similarité et également un seuil donné (plus de 0.7 en pratique)
- **Attachement des méta-données au template précédent** : cette étape vise à ajouter les informations des molécules identifiées et non identifiées sur leurs sommets respectifs du graphe.

Il faut noter que chacune des valeurs de seuil de similarité utilisées ont des significations particulières pour les biologistes. Si le seuil a une valeur supérieure à 0.7 alors on cherche des correspondances exactes, si par contre, on a une valeur comprise entre 0.63 à 0.7, on cherche des correspondances pour exploration.

Metabolomics And Dereplication By Two-dimensional Experiments (MADByTE)

MADByTE est également un outil qui permet de construire le réseau moléculaire correspondant à un ensemble de spectres de molécules ; il prend en entrée les spectres HSQC et TOCSY des molécules. Le réseau est tout de même différent qu'avec celui de GNPS, car on retrouve un nouveau type de nœud associé à un système de spin. Un système de spin est un ensemble de déplacements chimiques considérés comme identiques par tolérance. De ce fait, une molécule peut être vue comme un ensemble de systèmes de spins qu'il contient, et à cet effet son sommet est relié à tous ceux de ses systèmes de spins d'une similarité complète.

Comme on peut le voir sur la Figure 1.4, ils suivent les étapes suivantes :

- **Prétraitement des spectres HSQC et TOCSY** : cette étape vise à supprimer les déplacements considérés comme inutiles, en tenant compte des solvants qui ont été utilisés pour acquérir les spectres et en s'assurant qu'après suppression les spectres TOCSY soient toujours symétriques
- **Croisement des spectres TOCSY et HSQC obtenus** : cette étape vise à conserver les déplacements qui se correspondent par rapport aux atomes d'hydrogènes pour chacun des couples de spectres




FIGURE 1.4 – Processus de MADByTE

- **Calcul des système de spins** : cette étape vise à regrouper les déplacements identiques que sont les systèmes de spins avec des marges d'erreur donnés pour les atomes d'hydrogène et de carbone
- **Construction du réseau** : cette étape vise à construire le réseau de molécules. On calcule les similarités entre les systèmes de spins en utilisant l'indice de Jaccard. Il faut aussi noter que chaque sommet d'une molécule sera lié aux sommets de tous ses systèmes de spins d'une valeur de similarité complète (valeur 1)

On obtient un réseau qui, pour des raisons de lisibilité peut être simplifié en supprimant les sommets de systèmes de spins qui ne sont liés à aucun autre système. On obtient un **réseau d'association** qui peut encore être plus lisible en considérant les sommets de systèmes de spins connectés comme un sommet.

Nous remarquons que l'on utilise un réseau moléculaire parce qu'il permet d'explorer des liaisons entre les molécules, tout en regroupant les molécules ou encore spectres similaires dans des groupes ou encore clusters qui se forment naturellement. Ces groupes qu'on retrouve permettent par le biais d'observations et d'analyse des spectres, et des structures des molécules identifiées, d'avoir des orientations d'expérimentations. De ce fait les algorithmes comme GNPS et MADByTE regroupent des spectres de molécules les plus semblables, ce qui se rapproche très clairement du clustering.

1.4 Plan du mémoire

Le reste de ce mémoire est organisé comme suit. Le Chapitre 2 présente une revue de littérature des méthodes de clustering, de clustering multi-vues et d'ensemble de clustering utiles à la résolution du problème. Dans le Chapitre 3, nous détaillons les méthodes proposées. Le Chapitre 4 présente nos expérimentations et les résultats obtenus. Enfin, le Chapitre 5 conclut ce document en résumant les principaux résultats et en discutant des implications futures de notre recherche.

CHAPITRE 2

ÉTAT DE L'ART

2.1 Clustering

Le **clustering** est un processus d'analyse exploratoire qui consiste sur la base d'un ensemble de données, à regrouper ceux qui sont les plus similaires entre eux et d'en éloigner ceux qui le sont moins. Cette opération de regroupement amène à obtenir des groupes d'observations appelés clusters dans lesquels se trouvent des observations qui sont les plus similaires les unes, des autres.

Plusieurs approches de construction de clusters ou de regroupement d'observations ont vu le jour, ce qui a conduit à la création de divers algorithmes de clustering, qui peuvent être regroupés comme suit :

- **Clustering par partitionnement** : on cherche à construire des clusters qui seront disjoints entre eux et donc séparés, ce qui conduit à partitionner ou encore à diviser l'ensemble des observations. Les plus communs de ce type d'algorithmes sont l'algorithme KMEANS et l'algorithme de clustering spectral.
- **Clustering hiérarchique** : L'approche est de construire une hiérarchie de clusters des données, de façon ascendante ou descendante. Ascendante selon le fait qu'on débute la construction depuis chaque observation, et descendante en revanche en partant de tout l'ensemble des observations. Comme algorithmes les plus utilisés, on a les algorithmes Classification Ascendante Hiérarchique (CAH) et Classification Descendante Hiérarchique (CDH).
- **Clustering par modélisation** : l'idée est de construire des clusters qui seront modélisés d'une façon donnée. Communément les clusters sont modélisés par des modèles probabilistes, ce qui est le cas pour l'algorithme Gaussian Mixture Model (GMM).
- **Clustering par densité** : L'approche est celle d'identifier une zone d'observations à forte densité comme étant un cluster d'observations. L'algorithme Density-Based Spatial Clustering of Applications with Noise (DBSCAN) étant le plus populaire, avec des versions prenant des graphes non pondérés et planaires tels que l'algorithme Structural Clustering Algorithm for Networks (SCAN) et Network Space - Density-Based Spatial Clustering of Applications with Noise (NS-DBSCAN).

Les données spectrales telles que les spectres MS et RMN pouvant être impactées respectivement par la qualité de l'ionisation et des matériaux utilisés, peuvent avoir des bruits. De plus,




FIGURE 2.1 – Types clés d’observations de DBSCAN

les biologistes détectent les clusters dans les réseaux moléculaires en les considérant naturellement par des zones à densité relativement forte. De ce fait, utiliser des algorithmes de clustering par modélisation ou par densité sur de telles données est logique car ils ont principalement la propriété d’être résistants aux bruits. Nous parlerons ainsi par la suite, plus spécifiquement des algorithmes DBSCAN et ses versions pour les graphes SCAN et NS-DBSCAN.

2.1.1 Density-Based Spatial Clustering of Applications with Noise (DBSCAN)

DBSCAN est un algorithme de clustering utilisé pour regrouper des points de données similaires en définissant un cluster comme une zone à grande densité.

Soit $N(x, \epsilon)$ l’ensemble des observations voisines de l’observation x étant dans le rayon ϵ , on a :

$$N(x, \epsilon) = \{x' | d(x', x) \leq \epsilon\} \quad (2.1)$$

L’algorithme retrouve ces zones progressivement par parcours en largeur, grâce à des points d’intérêts qu’on peut voir à la Figure 2.1 qui sont :

- **Core Point** : observation caractérisée par le fait que le nombre de ses voisins dépasse le seuil de densité minimum $MinPts$
- **Border Point** : observation appartenant au voisinage d’un **Core Point** mais ne l’est pas
- **Noise Point** : est une observation qui n’est ni **Core Point**, ni **Border Point** c’est à dire du bruit

Des versions [13] de cet algorithme ont été mis en place dans le but de réduire son temps de calcul, de réduire l’impact de ses paramètres de densité sur la construction des clusters, et de prendre en compte de différentes natures des données d’entrée (image, texte, graphe, ...). On retrouve ainsi des algorithmes tels que SCAN et NS-DBSCAN qui permettent de prendre des graphes non pondérés en entrée et planaires respectivement.

2.1.2 Structural Clustering Algorithm for Networks (SCAN)

SCAN [14] est un algorithme de partitionnement de graphe non pondéré, ayant pour objectif de construire les groupes de sommets, en les voyant comme des zones à forte densité de sommets.

L'algorithme calcule premièrement pour chaque sommet du graphe l'ensemble de ses voisins (qui constitue sa structure), puis utilise l'algorithme DBSCAN avec pour mesure de similarité la distance cosinus.

2.1.3 Network Space - Density-Based Spatial Clustering of Applications with Noise (NS-DBSCAN)

NS-DBSCAN [15] est un algorithme de partitionnement de graphe planaire, qui a pour but de regrouper les sommets qui y sont contenus, en considérant ces groupes comme des zones à forte densité de sommets. L'algorithme utilise l'algorithme DBSCAN en considérant les sommets du graphe comme des observations et en utilisant comme distance entre sommets l'algorithme LSPD [15] (Local Shortest Path Distance).

Malgré le fait que ces deux précédents algorithmes prennent en entrée des graphes d'observations, ils ne tiennent pas compte des spécificités des réseaux moléculaires qui contiennent déjà les densités de voisinage.

2.2 Clustering Multi-vues

Le clustering multi-vues est une technique d'apprentissage non supervisée qui consiste à regrouper des observations similaires entre eux et d'en éloigner ceux qui ne le sont pas, en tenant compte du fait qu'on utilise pour chaque observation plusieurs représentations différentes appelées vues.

Le clustering multi-vues se différencie du "clustering" principalement par le fait qu'on cherche à exploiter la complémentarité et le consensus entre des vues de données dans le but de mieux les regrouper. La complémentarité et le consensus entre les vues sont donc des notions importantes à définir :

- **Complémentarité** : la complémentarité entre deux vues $V1$ et $V2$ est décrit par le fait qu'il existe sur des observations, des informations qui ne peuvent être représentées que par $V1$ et d'autres que par $V2$
- **Consensus** : le consensus entre deux vues $V1$ et $V2$ est décrit par le fait qu'il existe sur des observations, des informations qui sont décrites par $V1$ et par $V2$ simultanément

En considérant une dataset X avec deux vues X^1 et X^2 , Daguplaet et al. [16] ont démontré que la probabilité d'erreur issue du conflit des hypothèses (prédicteurs) f_1 et f_2 sur les vues X^1 et X^2 respectivement, est supérieure ou égale aux probabilités faites par f^1 ou f^2 sur ces mêmes vues. D'où minimiser le désaccord entre f^1 et f^2 sur les vues, permet de réduire les erreurs de f^1 et f^2 simultanément.

Cela a permis d'avoir les principes suivants qui constituent la base des algorithmes de clustering multi-vues :

- **Principe associé à la complémentarité** : les vues doivent être utilisées afin de décrire les observations de manière plus complète et plus précise.
- **Principe associé au consensus** : il faut maximiser le consensus ou encore la cohérence entre les vues des observations afin de mieux cerner les informations complémentaires entre les vues




FIGURE 2.2 – Taxonomie des algorithmes de clustering multi-vues [2]




FIGURE 2.3 – Processus général des algorithmes de clustering multi-vues de co-formation [3]

La mise en œuvre de ses principes a conduit à l’obtention des branches d’algorithmes tel qu’on peut le voir sur la Figure 2.2 : ceux qui apprennent des représentations globales des différentes vues des données et ceux qui ne le font pas.

2.2.1 Algorithmes sans apprentissage de représentation

Algorithmes de co-formation

Ces algorithmes cherchent à maximiser l’accord entre les vues tout en améliorant itérativement les clusters allant d’une vue à l’autre. On construit initialement les clusters pour chaque vue, et les clusters d’une vue sont améliorés en utilisant ceux des autres vues dans le but de maximiser le consensus d’observations entre eux. On procède ainsi tour à tour un certain nombre d’itérations (Figure 2.3) pour chaque vue. On peut trouver les algorithmes de co-formation [17] adaptant les algorithmes EM, CAH et KMEANS Sphérique .

Algorithmes multi-noyaux

S’il est difficile de construire des clusters dans un espace d’une dimension donnée, on pourrait plus aisément le faire en projetant les observations dans un espace correspondant de plus grande dimension. C’est sur ce principe que les algorithmes de clustering par noyaux sont construits. On recherche une fonction noyau qui permettra d’obtenir de meilleurs clusters suivant un critère d’évaluation comme l’inertie intra-classe. Cette fonction noyau agglomère les espaces des données différentes vues, en combinant linéairement ou non des fonctions noyaux obtenues sur chacune




FIGURE 2.4 – Processus général des algorithmes de clustering multi-vues multi-noyaux [3]

des vues (voir la Figure 2.4). On peut citer l'algorithme multi-noyau auto-pondéré [3] qui adapte KMEANS en modifiant la définition de l'inertie intraclasse avec une fonction noyau gaussienne pondérée.

Algorithmes de factorisation matricielle

Ils sont utilisés pour le problème de clustering multi-vues en factorisant les matrices de données des vues (non négatives) en des couples de matrices dit facteurs. Pour chacun de ces couples, on a l'un qui représente la pondération liée à une vue précise et l'autre l'indicateur des clusters pour cette même vue. Cet indicateur contenant de nouveaux vecteurs représentatifs d'observations très similaires pour ceux d'un même cluster et peu similaires pour ceux ne l'étant pas.

L'indicateur global des clusters est ainsi calculé par agglomération de chacune des vues par consensus. Plus formellement, on a le problème d'optimisation de l'équation 2.2, où $U^{(v)}$ désigne la matrice de poids de la vue v , $C^{(v)}$ l'indicateur de la vue v , C^* est l'indicateur globale et Φ est une fonction de différence de C^* et $C^{(v)}$. Il faut noter que $\|A\|_F^2 = \text{tr}(A.A^T) = \sum_{i,j} a_{i,j}^2$

$$\begin{aligned} \min \sum_{v=1}^V \|X^{(v)} - U^{(v)} \cdot C^{(v)}\|_F^2 + \Phi(C^{(v)}, C^*) \\ \text{s.t, } U^{(v)}, C^{(v)}, C^* \geq 0, \end{aligned} \quad (2.2)$$

Algorithmes spectraux

Effectuer du clustering revient à trouver k groupes d'observations similaires entre eux. Cela se fait par une fonction f qui permet d'attribuer à chaque observation un indicateur propre à un des K clusters. On peut ainsi voir que f est lui-même un indicateur pour attribuer une observation à un cluster donné et peut être vu comme une projection d'observations où les vecteurs appartenant au même cluster se ressemblent fortement et non pour ceux de clusters différents.

L'objectif de ces algorithmes est de calculer f , tout en tenant compte des similarités entre couple d'observations (on revient à un graphe de similarité) pour chacune des vues. Plus formellement on cherche à résoudre le problème d'optimisation 2.3 où L_v est le laplacien du graphe de similarité des observations dans la vue v , α_v l'importance attribué à la vue v .

$$\begin{aligned} \min_{F^T F = I, \alpha} \sum_v \text{tr}(F^T L_v F) \\ \text{s.t, } \sum_v \alpha_v = 1, \alpha_v \geq 0 \end{aligned} \quad (2.3)$$

La contrainte $F^T F = I$ permet de s'assurer que les nouvelles dimensions ne se corrèleront pas.




FIGURE 2.5 – Processus général des algorithmes de clustering multi-vues basés sur les graphes [2]

2.2.2 Algorithmes basés sur l'apprentissage de représentation

Algorithmes basés sur les graphes

Pour pouvoir tenir compte des données à plusieurs vues, ils construisent pour chaque vue des graphes de similarités, puis définissent une politique de fusion de ces graphes, qui s'appuie généralement sur l'attribution des poids à des observations par rapport aux groupes formés. De là on obtient un graphe unifié ou global de similarité qui pourra être sujet de partitionnement pour obtenir les clusters. On cherchera ainsi à trouver les poids amenant à avoir le moins d'erreurs possible de fusion des vues. On peut ainsi retrouver l'algorithme Multi-View Graph Learning (MVGL) [4] qui met en œuvre ce principe.

Plus formellement le problème d'optimisation générale est celui de l'équation 2.4, où $A^{(v)}$ est la matrice de similarité spécifique à la vue v , S représente la matrice de similarité du graphe unifié, Dis pour la similarité ou la dissimilarité utilisée dans les vues, et Φ est une fonction d'erreur de fusion de S et $A^{(v)}$.

$$\min \sum_{v=1}^V \sum_{i \neq j}^n Dis(X_i^{(v)}, X_j^{(v)}) A^{(v)} + \Phi(A^{(v)}, S) \quad (2.4)$$

$$\text{s.t, } A^{(v)}, S \geq 0,$$

Algorithmes de sous-espaces

L'idée ici est de rechercher une représentation unifiée des vues pour chaque observation, puis d'utiliser un algorithme de clustering dessus pour obtenir les clusters. De ce fait, on procède généralement de deux manières tel que sur la Figure 2.6 :

1. soit on apprend directement la représentation depuis les sous-espaces des vues des données
2. soit on apprend la représentation globale sur un espace latent issus de ses sous espaces des vues




FIGURE 2.6 – Processus général des algorithmes de clustering multi-vues de sous-espaces [3]




FIGURE 2.7 – Processus général des algorithmes de clustering multi-vues d'apprentissage profond de représentation [2]

Il faut noter que chaque sous espace des vues est généralement obtenue par réduction de dimension des données de ces dernières.

On peut citer l'algorithme Multi-View Clustering in Latent Embedding Space (MCLES) [18] qui est la base des algorithmes les plus performants de ce type.

Algorithmes basés sur l'apprentissage profond de représentation

Dans le but d'explorer complètement les espaces de données originaux pour construire une représentation unifiée, ces algorithmes utilisent des réseaux de neurones au vue de leur performance sur des problèmes supervisés. Comme le modèle d'auto-encodage [19] utilisé dans le domaine du traitement du langage naturel, ces réseaux sont entraînés par rétropropagation des erreurs liées aux regroupements effectués sur les représentations obtenues des observations. La Figure 2.7 illustre très bien le processus général de ces algorithmes.

2.2.3 Comparaison des algorithmes de clustering multi-vues

Nous avons le Tableau 2.1 de comparaison suivant mettant en évidence les avantages et limites des algorithmes en se basant sur leurs propriétés.

TABLE 2.1 – Tableau de comparaison des algorithmes de clustering multi-vues

Algorithmes	Avantages	Limites
Algorithmes de co-formation	- ils améliorent itérativement et simultanément les clusters de chaque vue - ils permettent d’obtenir des regroupements ”optimaux” dans chacune des vues	- ils reconstruisent les clusters à chaque étape, ce qui peut alourdir le temps de calcul des clusters optimaux
Algorithmes multi-noyaux	- ils permettent d’obtenir des clusters globaux dans un espace unifié de plus grande dimension (sans l’obtenir analytiquement) permettant d’obtenir les meilleurs regroupements - ils permettent de mettre une nouvelle observation dans un cluster sans pour autant relancer tout le processus - ils sont peu sensibles aux bruits	- on ne peut pas obtenir l’espace de plus grande dimension cible - ils dépendent fortement du choix de la fonction noyau unifiée (de la fusion des noyaux de chaque vue)
Algorithmes spectraux	- ils permettent d’obtenir un indicateur unifié des clusters tout en calculant et intégrant les importances des vues dans la construction des clusters	- l’attribution d’une nouvelle observation à un cluster nécessite un ré-apprentissage des paramètres - ils sont sensibles aux bruits - ils dépendent généralement de métriques de similarité spécifiques pour la construction des matrices de similarité, ce qui le rend instable - ils se basent uniquement sur les données des vues complètes
Algorithmes de factorisation	- ils permettent d’obtenir un indicateur unifié des clusters et des indicateurs spécifiques pour chacune des vues, tout en évaluant l’importance de ces vues dans les regroupements	- l’attribution d’une nouvelle observation à un cluster nécessite un ré-apprentissage des paramètres

Algorithmes basées sur les graphes	- ils permettent d'obtenir un graphe de similarité globale utile à l'exploration des données - ils sont peu sensibles aux bruits - ils permettent de réduire la dimensionnalité des données de chaque vues	- l'attribution d'une nouvelle observation à un cluster nécessite un ré-apprentissage des paramètres - ils dépendent généralement de métriques de dissimilarité et de similarité
Algorithmes de sous-espaces	- ils permettent d'obtenir une représentation globale des vues tout en optimisant les regroupements - ils permettent de réduire la dimensionnalité des données d'origine - ils sont peu sensibles aux bruits	- l'attribution d'une nouvelle observation à un cluster nécessite un ré-apprentissage des paramètres
Algorithmes basés sur l'apprentissage profond de représentation	- ils permettent d'obtenir une représentation unifiée des vues - l'attribution d'une nouvelle observation ne nécessite pas forcément un ré-apprentissage des paramètres	- on a le problème d'explicabilité du réseau

Au vue de cette analyse, les algorithmes de graphes et de sous espace sont ceux qui correspondent le plus à notre problème. Cela parce qu'ils sont résistants aux bruits ce qui est souhaitable vu que les données spectrales en contiennent. De plus les réseaux moléculaires étant des graphes de similarité, ils peuvent être utilisés dans les algorithmes de graphes ; et les algorithmes de sous espaces peuvent combiner des spectres de molécules en un seul (ce qui a fait partie d'une des idées initiales). Nous développons dans les sections qui suivent les algorithmes MCLES et MVGL qui font partie des plus performants de ces catégories.

2.2.4 Multi-View Clustering in Latent Embedding Space (MCLES)

L'idée ici est de construire une représentation unifiée (une nouvelle représentation combinée des vues) dans un espace latent, afin de calculer une matrice de similarité de cette représentation qui sera utilisée pour effectuer les regroupements. Cela dit, en entrée on a les données des vues et le nombre voulu de clusters, pour avoir en sortie la représentation unifiée, les indicateurs de clusters des observations et les clusters après utilisant de l'algorithme KMEANS. Comme la Figure 2.8 le montre on calcule d'abord la représentation unifiée, puis la matrice de similarité et enfin les indicateurs de clusters d'observations itérativement jusqu'à ce qu'on obtienne le meilleur clustering possible ou après un certains nombre d'itérations.




FIGURE 2.8 – Processus de l’algorithme MCLES

En supposant que la représentation unifiée d’une observation le décrit pleinement, on peut retrouver sa représentation pour une vue, en appliquant sur cette représentation unifiée une tâche donnée qui peut être une pondération (projection). Plus formellement pour l’observation i , on a $x_i^{(v)}$ son vecteur caractéristique dans la vue v , h_i étant sa représentation unifiée et $W^{(v)}$ étant la matrice des poids de la vue v .

$$x_i^{(v)} = W^{(v)} h_i$$

En considérant que les observations sont des colonnes de matrices de données des vues, on obtient l’expression suivante

$$X = WH \text{ où } X = \begin{pmatrix} X^{(1)} \\ X^{(2)} \\ \vdots \\ X^{(V)} \end{pmatrix}, W = \begin{pmatrix} W^{(1)} \\ W^{(2)} \\ \vdots \\ W^{(V)} \end{pmatrix}$$

Ainsi pour obtenir W et H , on minimise la différence entre les données des vues et le produit de H et W . Ce qui nous conduit au problème suivant à résoudre :

$$\begin{aligned} \min_{W, H} \|X - WH\|_F^2 \text{ s.t. } \|W_{:,j}\|_2^2 &\leq 1 \\ X &= \begin{pmatrix} X^{(1)} \\ X^{(2)} \\ \vdots \\ X^{(V)} \end{pmatrix}, W = \begin{pmatrix} W^{(1)} \\ W^{(2)} \\ \vdots \\ W^{(V)} \end{pmatrix} \end{aligned} \quad (2.5)$$

Avec la représentation unifiée, on calcule la matrice de similarité entre les observations. Pour le faire, on s’appuie sur le fait qu’une observation est sensiblement égale à une combinaison linéaire

des autres où les coefficients sont les similarités entre l'observation en question et les autres observations. En effet, la similarité entre deux observations peut être également décrite comme le pourcentage d'influence qu'à l'un sur l'autre et vis versa. Soit S comme la matrice de similarité des observations, on a :

$$h_j \simeq \sum_i h_i S_{ij}$$

Pour obtenir S , on minimise la différence entre la représentation unifiée et les données qu'on obtient après application des poids de similarité. Ce qui conduit au problème suivant, avec régularisation ;

$$\begin{aligned} \min_S & \|H - HS\|_F^2 + \beta \|S\|_F^2 \\ \text{s.t. } & S_{:,j} \mathbf{1} = 1, 0 \leq S \leq 1 \end{aligned} \quad (2.6)$$

Ayant la matrice de similarité, on calcule l'indicateur de clusters P qui est une projection des observations où les vecteurs appartenant au même cluster se ressemblent fortement et non pour ceux de clusters différents. Pour le faire, on s'appuie sur le fait que la différence entre les vecteurs p_i et p_j de deux observations i et j , associée à leur similarité S_{ij} , peut être vue comme une erreur d'attribuer ses vecteurs. Ce qui permet d'obtenir P en minimisant la somme de ces erreurs pour tous les couples possibles d'observations. Plus formellement, on a le problème suivant à résoudre, avec P la matrice indicatrice, L_S étant le laplacien du graphe issu de S :

$$\begin{aligned} \min_P & \sum_{i,j} \|p_i - p_j\|^2 s_{ij} = \text{Tr}(P^T L_S P) \\ \text{s.t. } & P^T P = I \end{aligned} \quad (2.7)$$

Dans le but de calculer simultanément tous ces paramètres, on réunit les trois problèmes 2.5, 2.6 et 2.7 en le problème suivant :

$$\begin{aligned} \min_{W,H,S,P} & \underbrace{\|X - WH\|_F^2}_{\text{apprentissage de la représentation unifiée}} + \underbrace{\alpha \|H - HS\|_F^2 + \beta \|S\|_F^2}_{\text{apprentissage de la matrice globale}} + \underbrace{\gamma \text{Tr}(P^T L_S P)}_{\text{apprentissage de l'indicateur de clusters}} \\ \text{s.t. } & \|W_{:,j}\|_2^2 \leq 1, S_{:,j} \mathbf{1} = 1, 0 \leq S \leq 1, P^T P = I \end{aligned} \quad (2.8)$$

Pour résoudre ce problème, on a l'algorithme d'optimisation suivant :

Algorithme 1 Algorithme d'optimisation MCLES [18]

Entrée: Données d'entrée X , les constantes de régularisations α, β, γ , la dimension de l'espace latent d , k le nombre de cluster

- 1: Initialiser $H, P, W = 0, S = 0$
 - 2: **repéter**
 - 3: Résoudre le problème 2.8 avec pour seul variable W (α, β, γ ne sont pas considérées)
 - 4: Résoudre le problème 2.8 avec pour seul variable H (β, γ ne sont pas considérées)
 - 5: Résoudre le problème 2.8 avec pour seul variable S (γ n'est pas considéré)
 - 6: Résoudre le problème 2.8 avec pour seul variable P (clustering spectral)
 - 7: **tantque** convergence
 - 8: **retourner** W, H, S, P
-

Pour résoudre l'équation 2.8 en considérant comme unique variable W , on utilise l'algorithme ADMM . Cette algorithme ADMM permet de résoudre un problème d'optimisation donné, après y avoir introduit de nouvelles variables, permettant de le transformer en une suite de problèmes plus simple à résoudre. Ces variables dépendantes linéairement de ceux du problème initial ont ainsi pour but de simplifier le problème de départ.

Par la suite pour H , on retrouve après développement de la relation de nullité du gradient du lagrangien (des conditions de KKT) l'équation de Sylvester suivante :

$$W^T W H^* + H^* * \alpha(I - S)(I - S)^T = W^T X \quad (2.9)$$

où I est la matrice identité.

Après développement du problème 2.8, on revient pour S au problème d'optimisation quadratique suivant :

$$\begin{aligned} \min_{S_{:,i}} S_{:,i}^T \left(\frac{\beta}{\alpha} I + K \right) S_{:,i} + \left(\frac{\gamma b_i^T}{2\alpha} I - 2K_{:,i} \right) S_{:,i} \\ \text{s.t. } S_{:,j} \mathbf{1} = 1, 0 \leq S \leq 1 \end{aligned} \quad (2.10)$$

où $K = H^T H$ et $b_{ij} = \|P_{i,\cdot} - P_{j,\cdot}\|^2$

En développant la relation de nullité du gradient du lagrangien (des conditions de KKT) du problème, on retrouve la variable optimale P^* en calculant les c premiers vecteurs propres du laplacien L_S du graphe issu de S dans l'ordre croissant de leur valeur propre, avec c étant en pratique le nombre de clusters voulus.

2.2.5 Multi-View Graph Learning (MVGL)

L'idée de l'algorithme est de construire pour chaque vue un graphe de similarité dénué des biais de ses données, puis de combiner ces graphes par pondération des arêtes afin d'obtenir un graphe globale contenant des composantes connexes qui seront ainsi les clusters voulus. En entrée, on a les données des vues avec le nombre voulu de clusters, pour avoir en sortie un graphe globale de similarité des observations contenant les clusters. La Figure 2.9 présente le fonctionnement de cet algorithme.

Soit K le nombre de clusters voulus. En supposant qu'un graphe dénué de biais de données est un graphe ayant déjà K composantes connexes (clusters), on va en construire pour chacune des vues en s'appuyant sur leurs données.

Pour chaque vue v , considérons qu'on a une projection des observations nommée Q tel que les vecteurs d'observations du même groupe sont très similaires et peu pour ceux de groupes différents ; et une matrice S d'adjacence du graphe voulu. On peut à cet effet voir la différence entre les vecteurs q_i et q_j de deux observations i et j associée à leur similarité S_{ij} (si elles sont connectés), comme une erreur. Ce qui permet d'affirmer qu'en minimisant la somme de ces différences pondérés pour tous les couples d'observations, on calcule simultanément ces vecteurs indicateurs et la matrice d'adjacence du graphe.

Plus formellement pour chaque vue v , on construit un graphe de matrice d'adjacence $S^{(v)}$ avec les vecteurs indicateurs Q^v , en résolvant le problème d'optimisation suivant où S correspond à $S^{(v)}$, Q à l'indicateur de clusters pour la vue, $L = D - \frac{(S+S^T)}{2}$ au laplacien du graphe avec D étant la matrice de degré de $\frac{(S+S^T)}{2}$, et j étant l'indice d'une observation.

$$\begin{aligned} \min_{Q,S} \text{Tr}(Q^T L Q) + \beta \|S\|_F^2 \\ \text{s.t. } \forall j, \mathbf{1}^T s_{:,j} = 1, s_j \geq 0, Q^T Q = I \end{aligned} \quad (2.11)$$




FIGURE 2.9 – Workflow de l'algorithme MVGL [4]

D'où l'algorithme :

Algorithme 2 Algorithme d'apprentissage des graphes des vues [4]

Entrée: Données d'entrée $X = \{X^{(1)}, X^{(2)}, \dots, X^{(V)}\}$, la constante de régularisation β , k le nombre de clusters

- 1: Initialiser pour chaque vue v , $Q^{(v)}$ avec $X^{(v)}$,
 - 2: **pour** $v \in [1, V]$ **faire**
 - 3: **répéter**
 - 4: résoudre le problème 2.11 avec pour seule variable $S^{(v)}$
 - 5: résoudre le problème 2.11 avec pour seule variable $Q^{(v)}$
 - 6: **tantque** $S^{(v)}$ a k composantes connexes
 - 7: **fin pour**
 - 8: retourner S , Q
-

En développant le problème 2.11 en considération comme seule variable S , on obtient le problème quadratique suivant à résoudre :

$$\begin{aligned} \min_{s_j} & \left\| s_j + \frac{1}{2\beta} g_j \right\|_2^2 \\ \text{s.t. } & \forall j, \mathbf{1}^T s_j = 1, s_j \geq 0 \end{aligned} \quad (2.12)$$

où $g_{ij} = \|q_i - q_j\|^2$

Pour résoudre le problème 2.11 en considérant comme unique variable Q , on retrouve par développement de la relation de nullité du gradient lagrangien (des conditions de KKT) la variable optimal Q^* . Q^* étant constitué les K premiers vecteurs propres du laplacien du graphe issu de S , selon l'ordre croissant de leur valeur propre, avec K étant le nombre de clusters voulus.

Pour fusionner les graphes des vues, il suffit pour chaque couple d'observations, de sommer pourcentages des poids des arêtes les liant dans les graphes des vues. En considérant que la matrice d'adjacence A du graphe globale peut être donnée, la différence entre elle et la somme pondérée des matrices d'adjacence des graphes des vues peut être vue comme une erreur.

Dans le même principe de construction des graphes des vues, on considère une matrice indicatrice P des observations de tel sorte que les vecteurs d'observations de même groupe sont très similaires et peu pour celles de groupe différent. On revoit ainsi la différence entre deux vecteurs p_i et p_j de deux observations i et j pondérée par leur similarité a_{ij} (si elles sont connectées) comme une erreur.

Plus formellement, pour construire le graphe unifié des graphes uniques à chaque vue, on résout le problème d'optimisation suivant, où A correspond à la matrice d'adjacence du graphe globale, P à l'indicateur de clusters globale et W aux poids d'influence pour chacune des vues sur chacune des observations.

$$\begin{aligned} \min_{A, W, P} \sum_{j=1}^n \left\| a_j - \sum_{v=1}^V w_j^{(v)} s_j^{(v)} \right\|_2^2 + \gamma \text{Tr}(P^T L P) \\ \text{s.t. } \forall j, \mathbf{1}^T a_j = 1, a_j \geq 0, \sum_{v=1}^V w_j^{(v)} = 1 \\ P \in \mathbb{R}^{k \times n}, P^T P = I \end{aligned} \quad (2.13)$$

D'où l'algorithme :

Algorithme 3 Algorithme d'apprentissage du graphe globale [4]

Entrée: Les matrices de similarité des graphes des vues $S = \{S^{(1)}, S^{(2)}, \dots, S^{(V)}\}$, la constante de régularisation γ , k le nombre de clusters

- 1: Initialiser $W = \frac{1}{V}$, $a_j = \sum_{v=1}^V w_j^{(v)} s_j^{(v)}$
 - 2: résoudre le problème 2.13 avec pour seul variable P
 - 3: **tant que** il n'y a pas de convergence **faire**
 - 4: **repéter**
 - 5: résoudre le problème 2.13 avec pour seul variable A
 - 6: résoudre le problème 2.13 avec pour seul variable P
 - 7: **tant que** A a k composantes connexes
 - 8: résoudre le problème 2.13 avec pour seul variables W
 - 9: **fin tant que**
 - 10: retourner A, P, W
-

En développant le problème 2.13 en considérant comme unique variable A , on obtient le problème quadratique suivant :

$$\begin{aligned} \min_{a_j} \left\| a_j + \left(\frac{1}{2\beta} h_j - \sum_{v=1}^V w_j^{(v)} s_j^{(v)} \right) \right\|_2^2 \\ \text{s.t. } \forall j, \mathbf{1}^T a_j = 1, a_j \geq 0 \end{aligned} \quad (2.14)$$

où $h_{ij} = \|p_i - p_j\|^2$

La résolution du problème 2.13 en considérant comme unique variable P , est la même que pour celui du problème 2.11 avec pour unique variable Q , en voyant Q comme P et S comme A .

Pour résoudre ce même problème en considérant W comme unique variable, on développe la condition de nullité du gradient lagrangien (des conditions de KKT) afin d'obtenir la relation suivante :

$$w_j = \frac{\left(Z_j^T Z_j \right)^{-1} \mathbf{1}}{\mathbf{1}^T \left(Z_j^T Z_j \right)^{-1} \mathbf{1}} \quad (2.15)$$




FIGURE 2.10 – Processus général des algorithmes de correspondance forte

où $z_j^{(v)} = a_j - s_j^{(v)}$

2.3 Algorithmes d'ensemble de clustering

Construire des clusters issues de ceux de base (issus des algorithmes de base), revient à construire un ensemble C de K clusters qui se rapprocheront le mieux possible de ceux de base. En d'autres termes on souhaite un ensemble de clusters final, qui aura un minimum de désagrément avec les clusters de base. De là, on peut se rendre compte que la principale difficulté à franchir est celle de trouver les correspondances entre les différents clusters de base. Dans le but de le faire, plusieurs approches ont été proposées dont les suivantes.

2.3.1 Algorithmes de correspondance forte

L'idée de ces algorithmes est de rechercher la correspondance entre les clusters de weak-learners différents en supposant qu'on a pour chaque cluster d'un weak-learner son correspondant dans un autre weak-learner. On peut donc voir que cela conduit à trouver un ré-ordonnancement, une permutation entre les clusters de différents weak-learners, qui permet d'avoir le consensus le plus élevé entre les clusters des weak-learners. La figure 2.10 illustre le principe.

On peut citer les travaux de Sandrine Dudoit et Jane Fridlyand [20] qui ont proposés deux versions de l'algorithme Bagging dans ce sens.

2.3.2 Algorithmes de correspondance légère

Pour réduire le temps du calcul des algorithmes de correspondance forte, On pourrait calculer des correspondances plus légères entre les clusters de chaque weak-learner. Pour le faire, ces algorithmes passent généralement par la formulation qui suit : soient $S(m)$ la matrice de correspondance entre les clusters du m - ème weak-learner et les clusters finaux, de tel sorte que $S_{k',k}(m) = 1$ si le cluster k' du weak-learner m de base correspond au cluster finale k , $S_{k',k}(m) = 0$ sinon ; $M(m)$ comme étant la matrice d'assignation des observations aux clusters du m - ème weak-learner où $M_{i,k'}(m) = 1$ si l'observation i est dans le cluster k' du weak-learner de base, $M_{i,k'}(m) = 0$ sinon ; et C la matrice d'assignation des observations aux clusters finaux. On a ainsi le problème d'optimisation générale suivant :

$$\min \|C - MS\|^2 \quad (2.16)$$

Pour résoudre ce problème, on utilise généralement l'algorithme EM où les matrices de correspondance sont les variables cachées et la matrice d'assignation est la variable qu'on recherche.

2.3.3 Algorithmes basés sur les observations

L'idée ici est de représenter une observation, par l'ensemble des étiquettes de clusters dans lesquels il se trouve. Ce qui permet de construire de nouveaux clusters grâce à l'utilisation d'un second algorithme de clustering.

Ce second algorithme de clustering ayant principalement pour but de construire les clusters finaux de consensus, on définit généralement des fonctions pour l'évaluer :

- La moyenne des informations mutuelles normalisées entre les clusters finaux et les clusters de base décrit dans [21], avec M le nombre de weak-learners, C la colonne d'étiquettes de clusters globaux, $B(m)$ la colonne d'étiquettes de clusters du weak-learner m

$$\max_C \frac{1}{M} \sum_{m=1}^M NMI(C, B(m)) \quad (2.17)$$

- La fonction objective du clustering de corrélation décrit dans [22], avec S_{ij} étant le nombre de clusters de base où on retrouve les observations i et j simultanément

$$\max \sum_{i,j, C(i)=C(j)} (1 - S_{i,j}) + \sum_{i,j, C(i) \neq C(j)} S_{i,j} \quad (2.18)$$

Comme second algorithme de clustering, on a généralement :

- Algorithme de clustering hiérarchique [22] : CAH, CDH
- Algorithme LocalSearch modifié [22] : on initialise au départ éventuellement les clusters aléatoirement, puis on change le cluster d'une observation, si en le faisant la valeur de la fonction objective s'améliore, on le fera tant qu'il est possible d'améliorer la fonction objective
- Algorithmes de partitionnement de graphes : Cluster-based Similarity Partitioning Algorithm (CSPA), ... Ici on réalise le partitionnement du graphe des données où un nœud est une observation et une arête porte la similarité entre observations.
- L'algorithme EM modifié pour des distributions multinomiaux

2.3.4 Algorithmes basés sur les clusters

Dans l'optique de s'appuyer directement sur les clusters de base, on représente chacun d'eux comme un vecteur binaire d'appartenance des observations. Puis on les regroupe en un nombre donné de groupes finaux de clusters, puis on assigne chaque observation au groupe de clusters qui possède le plus de clusters le contenant. On peut citer les algorithmes Meta-CLustering Algorithm (MCLA)[21] et Adaptive Clustering Ensemble (ACE)[5].

2.3.5 Algorithmes basés sur les clusters et les observations

L'idée est de tenir compte des observations et des clusters pour construire les clusters finaux en les représentant dans une structure commune. Généralement on les représente en deux types de graphe :

- hyper-graphe : ici un noeud est une observation et une hyper-arête est un cluster de base
- graphe bipartie : ici on a deux ensembles de noeuds, l'ensemble des noeuds des observations et l'ensemble des noeuds des clusters de base, une arête est la liaison entre une observation et un cluster de base qui le contient.

Ces graphes permettent par leur coupure d'obtenir les K clusters finaux recherchés.

Par exemple, l'algorithme HGPA [21] représente les clusters de base et les observations avec un hypergraphe.

2.3.6 Comparaison des algorithmes d'ensemble de clustering

Nous avons le tableau 2.2 de comparaison suivant mettant en évidence les avantages et limites des algorithmes en se basant sur leurs propriétés

TABLE 2.2 – Tableau de comparaison des algorithmes d'ensemble de clustering

Algorithme	Avantages	Limites
Algorithmes de correspondance forte	- ils permettent d'avoir les correspondances entre les regroupements de base	- ils nécessitent que chaque weak-learner retourne un même nombre de clusters - ils sont coûteuses en temps à cause la recherche des correspondances par permutation
Algorithmes de correspondance légère	- ils prennent en considération le fait que chaque weak-learner peuvent fournir des nombres différents de cluster	- Deux clusters d'un même weak-learner de base peuvent correspondrent à un même cluster finale - La ressemblance entre les clusters de weak-learners différents ne sont pas réellement pris en compte

Algorithmes basés sur les observations	- Ces méthodes tiennent compte du fait que les weak-learners de base peuvent fournir des clusters de nombres différents	- d'après les opérations qu'ils utilisent, ils prennent beaucoup de temps lorsqu'on a beaucoup d'observations - ils sont sensibles à une grande variabilité de la constitution des clusters des différents weak-learners - ils dépendent généralement de métriques de dissimilarité et de similarité utilisées
Algorithmes basés sur les clusters	- ils tiennent compte du fait qu'une observation ne soit pas assigner à un cluster par au moins un weak-learner - ils assignent les observations à des groupes de clusters grâce à leur occurrence et dont s'attèlent au vote majoritaire - ils sont moins sensibles à une grande variabilité de la constitution des clusters des différents weak-learners - ils tiennent compte de la ressemblance des clusters de base	- ils dépendent généralement de métriques de dissimilarité et de similarité utilisées
Algorithmes basés sur les clusters et les observations	- ils intègrent les clusters de base et les observations simultanément - ils permettent de réduire la dimensionnalité des données d'origine	- Ils sont sensibles à une grande variabilité de la constitution des clusters des différents weak-learners

De ces comparaisons, nous voyons que les algorithmes basés sur les clusters se rapprochent plus du vote majoritaire des méthodes d'apprentissage ensemblistes. Nous présenterons ainsi par la suite les algorithmes ACE et MCLA qui font partie des plus performant de cette catégorie.

2.3.7 Adaptive Clustering Ensemble (ACE)

L'idée ici est de construire les clusters finaux par fusion des clusters de base similaire et d'attribuer les observations à ces clusters grâce à leurs pourcentages d'appartenance, en utilisant des




FIGURE 2.11 – Processus de l’algorithme ACE [5]

seuils de similarité adaptés au besoin. Pour le faire l’algorithme ACE, suit trois étapes qui sont visibles sur la Figure 2.11 :

1. Transformation des clusters issues des algorithmes de base

Cette étape consiste à transformer chaque cluster de base en un vecteur binaire où la i -ème composante est égale à 1 si l’observation i est dans le cluster, et 0 sinon

2. Calcul des K groupes de clusters de consensus

Cette étape consiste à construire K groupes des clusters de base (méta-cluster) en deux temps.

Dans un premier temps, on regroupe les couples de clusters qui ont une similarité (coefficient de Pearson supérieur à un seuil donné α_1 adapté pour obtenir au moins K groupes.

Dans un second temps, on va vérifier si K méta-clusters ont chacun au moins une observation certaine de leur appartenir. Une observation est certaine d’appartenir à un méta-cluster si sa similarité d’appartenance au méta-cluster (mesurée en utilisant la formule 2.19) dépasse un seuil α_2 donné. Si c’est le cas, on considère ces méta-clusters comme groupes à exploiter, sinon on considérera plutôt les K méta-clusters qui ont les plus grandes moyennes de similarité d’appartenance d’observations.

3. Assignation des observations aux groupes (méta-clusters)

Cette étape consiste à construire les clusters finaux, en assignant les observations aux K groupes obtenus qui peuvent être vus comme des clusters. Cela s’effectue, en assignant les observations aux groupes auxquelles elles sont certaines d’appartenir. Les autres observations seront ajoutées aux clusters dont elles perturberont le moins la qualité. La qualité de groupe étant calculée en évaluant la variance des similarités d’appartenance des observations d’un groupe, de formule 2.20.

Il faut noter que la similarité d’appartenance d’une observation i à un groupe g correspond au pourcentage du nombre de clusters du groupe, dans lesquels elle a été retrouvée.

$$S_x(x_i, c_g) = \frac{\theta(x_i, c_g)}{\max\{\theta(x_i, C)\}} \quad (2.19)$$

avec, x_i étant la i -ème observation, c_g étant le g -ème groupe de clusters, C étant l’ensemble des groupes de clusters, $\theta(x_i, c_g)$ étant le nombre de clusters de c_g où on trouve l’observation.

De plus la qualité d'un groupe c est la variance $\text{Var}(c)$ des similarités d'appartenance de ces observations, on a :

$$\text{Var}(c) = \frac{1}{\|c\|} \sum_{i=1}^{\|c\|} (S_x(x_i, c) - \rho_c) \quad (2.20)$$

avec ρ_c la moyenne de similarité d'appartenance d'observations du groupe c .

2.3.8 Meta-CLustering Algorithm (MCLA)

L'idée de l'algorithme est de regrouper les clusters de base en K groupes de clusters appelés méta-clusters, puis d'assigner chaque observation au méta-cluster qui possède le plus de clusters le contenant. Pour le faire l'algorithme MCLA suit les étapes suivantes :

1. Transformation des clusters de base

Cette étape consiste à transformer chaque cluster de base en un vecteur binaire où la i -ème composante est égale à 1 si l'observation i est dans le cluster, et 0 sinon

2. Construction du graphe de similarité de ces clusters

Cette étape consiste à construire un graphe, où les sommets sont les clusters de base, et où les arêtes portent les similarités entre ces clusters. La similarité entre deux clusters étant mesurée par l'indice de Jaccard de ces derniers, qui est décrit comme suit :

Soit a et b étant des clusters de base, l'indice de Jaccard $S(a, b)$ entre eux, est calculé en utilisant la formule suivante :

$$S(a, b) = \frac{|a \cap b|}{|a \cup b|} = \frac{h_a^T h_b}{\|h_a\|_2^2 + \|h_b\|_2^2 - h_a^T h_b} \quad (2.21)$$

avec h_a et h_b étant les vecteurs binaires des clusters a et b respectivement

3. Regroupement des clusters en K méta-clusters

Cette étape consiste à regrouper les clusters en K groupes de clusters similaires appelés méta-clusters. Pour le faire, on réalise une coupure du graphe de similarité obtenu à l'étape précédente, en utilisant METIS

METIS procède en trois étapes principaux : il réduit la taille du graphe en fusionnant successivement des noeuds adjacents en des multi-noeuds, il partitionne le graphe obtenu avec des algorithmes tel que l'algorithme de partitionnement spectral, et étend au final ce partitionnement au graphe d'origine par segmentation des multi-noeuds construits et affectation des noeuds aux clusters formés.

On pourra ainsi en pratique pour chaque groupe obtenu, sommer les vecteurs binaires de ses clusters, pour compter pour chaque observation, le nombre de clusters du groupe qui lui contiennent.

4. Construction des clusters finaux

Cette étape consiste à attribuer chaque observation au méta-cluster qui possède le plus de clusters de base le contenant.

Des deux algorithmes précédents, MCLA par son processus se rapproche le plus du vote majoritaire des algorithmes d'apprentissage par ensemble, qui permet de rendre plus robuste le modèle globale et de réduire le risque de sur-apprentissage.

En somme, il était question pour nous de faire un état des algorithmes à notre connaissance qui permettent d'avoir des briques de réponse à la question de recherche posée. Nous pouvons citer les algorithmes de clustering à une vue, de clustering multi-vues et d'ensemble de clustering. Au vue des caractéristiques propres aux données spectrales (comme la présence de biais) et de la nature des réseaux moléculaires, nous avons présenté plus en détail les algorithmes de clustering DBSCAN, SCAN, ; de clustering multi-vues MCLES et MVGL ; et d'ensemble de clustering ACE et MCLA. Dans les lignes qui suivent nous proposerons des algorithmes basés sur les algorithmes d'apprentissage par ensemble Bagging et Boosting pour atteindre l'objectif fixé.

CHAPITRE 3

ALGORITHMES PROPOSÉS ET EXPÉRIMENTATIONS

3.1 Algorithmes proposés

3.1.1 Introduction

Dans le but d'identifier plus efficacement les réseaux moléculaires, nous présenterons dans ce chapitre les approches que nous proposons qui s'appuient sur les apprentissages ensemblistes Bagging et Boosting. Le premier utilise l'approche Bagging qui consiste à construire des échantillons aléatoirement de taille donnée, qui seront utilisés par des modèles de base pour construire des clusters, qui seront par la suite combinées par vote majoritaire. Le deuxième utilise l'approche Boosting, qui par contre construit les échantillons en sélectionnant progressivement les observations mal regroupées par les weak-learner, en utilisant les clusters issues de GNPS et MADByTE comme oracle (vérité de regroupement). Dans les deux méthodes, nous utilisons MCLA pour le vote majoritaire et pondéré.

3.1.2 Méthode de type Bagging

Elle se déroule en plusieurs étapes suivantes qu'on peut retrouver sur la Figure 3.1 :

Calcul des réseaux moléculaires

Premièrement nous calculons les réseaux moléculaires issues des spectres MS et RMN en utilisant les solutions GNPS et MADByTE respectivement.

Calcul des clusters contenus dans les réseaux moléculaires

Pour détecter des groupes de molécules visibles sur un réseau moléculaire, les biologistes par nature repèrent les zones de forte densité de molécules y contenus.

Pour calculer ses clusters, nous utilisons l'algorithme DBSCAN en définissant le voisinage d'une molécule comme étant l'ensemble des molécules connectées à lui dans le réseau moléculaire. Vu que cette définition varie en fonction du type de réseau, nous avons le voisinage d'une molécule étant :




FIGURE 3.1 – Processus de l’approche de type Bagging

- l’ensemble des molécules qui lui sont adjacents pour un réseau de GNPS
- l’ensemble des molécules qui partagent au moins un système de spin avec lui pour un réseau de MADByTE

Transformation des spectres MS et RMN pour l’apprentissage multivues

Ici nous transformons les spectres MS et RMN en utilisant l’idée de l’outil MSpectraAI¹ qui est de définir des fenêtres de masse sur charge (de même taille) sur les spectres MS, puis d’agréger les intensités relatives y contenus pour obtenir un vecteur d’intensités indexé par les identifiants des fenêtres.

Pour les spectres MS, on définit un intervalle de valeur de masse sur charge de radicaux à considérer. Par la suite, nous segmentons le spectre d’entrée en fenêtres de même taille par rapport aux valeurs de masse sur charge. Chaque fenêtre obtenue va correspondre à une composante du vecteur final, cette composante qui contiendra la valeur agrégée (somme ou moyenne) des intensités relatives observées dans la fenêtre.

Pour les spectres RMN, on définit un intervalle de valeur de déplacement à considérer pour chaque type d’atomes considérés. Comme pour les spectres MS, on va segmenter le spectre RMN en fenêtres de même taille puis faire une agrégation des intensités. Ainsi si on a des spectres 2-RMN on aura en sortie une grille (vecteur ou matrice) d’intensité ou d’occurrence de croisement de déplacements. D’où le pseudo-algorithme :

1. Site officiel de l’outil MSpectraAI <https://bio.tools/mspectraai>

Algorithme 4 Algorithme de prétraitement de spectres

Entrée: spectre s , intervalles de déplacement I , fonction d'agrégation arg

Sortie: vecteur v

- 1: $windows = \text{split}(s, I)$;
 - 2: $v = 0$
 - 3: **pour tout** i allant de 1 à $|windows|$ **faire**
 $v[i] = \text{arg}(windows[i])$
 - 4: **fin pour**
-

Construction des clusters en utilisant la complémentarité et le consensus entre les spectres MS et RMN des molécules

Pour pouvoir tenir compte de la complémentarité et du consensus des spectres MS et RMN, nous utilisons comme algorithme de base MCLES ou MVGL, en introduisant lors du vote majoritaire (avec MCLA) les clusters détectés automatiquement sur les réseaux moléculaires venant de GNPS et MADByTE. Pour chaque weak-learner fournissant les K clusters voulus, on utilisera un échantillon construit par sélection aléatoire sans remise d'un pourcentage p d'observations d'entrées.

Affectation des clusters aux réseaux moléculaires

Les clusters intégrant la complémentarité et le consensus des spectres MS et RMN, tout en tenant compte des clusters détectés par les biologistes, il nous faut les introduire dans les réseaux pour améliorer leur qualité. Pour le faire pour chaque molécule, nous ajoutons dans les métadonnées de nœuds correspondants des réseaux obtenus (de GNPS et de MADByTE), son étiquette de cluster qui peut se caractériser visuellement par un coloriage ou une forme précise.

3.1.3 Méthode de type Boosting

Cette méthode se déroule comme la précédente en modifiant l'étape de construction des clusters pour tenir compte de la complémentarité des spectres. Cette construction diffère de la méthode précédente par la méthode d'apprentissage par ensemble Boosting utilisée dont le workflow est représenté à la Figure 3.2

Nous adaptons l'algorithme Adaboost avec comme weak-learner MCLES ou MVGL, pour permettre de construire itérativement des clusters de meilleurs qualités par échantillonnage d'observations. Nous considérons qu'une observation est **bien classée** (ou encore bien regroupée) quand toutes les molécules du même cluster que lui par rapport au weak-learner, le sont aussi par rapport aux réseaux moléculaires issues de GNPS et MADByTE. Les clusters extraites des réseaux de GNPS et de MADByTE deviennent ainsi des oracles permettant de s'assurer que les modèles de base intègrent progressivement leurs constructions.




FIGURE 3.2 – Processus de l'approche de type Boosting

3.1.4 Conclusion

En définitive, il était question pour nous de présenter les approches proposées pour accélérer l'identification des molécules en laboratoire, en regroupant leurs spectres MS et RMN en tenant compte de leur complémentarité et de leur potentiel consensus, ce qui permet par ricochet d'identifier les réseaux moléculaires les contenant. Dans la suite nous réaliserons les expérimentations sur la méthode de type Bagging en s'appuyant sur l'étape de construction des clusters.

3.2 Expérimentations et Résultats

En raison des difficultés d'accès aux données spectrales MS et RMN communes sur des molécules ainsi que de l'accès au code source de GNPS, nous avons mené les expérimentations sur l'étape de construction des clusters de l'approche de type Bagging.

3.2.1 Jeu de données

Nous avons mené les expérimentations sur la dataset MSRC-V1 d'images qui contient 210 objets pour 7 classes. Les 7 classes correspondent à des arbres, des bâtiments, des avions, des visages, des voitures, des bœufs et des bicyclettes. Ce dataset contient 4 vues qui correspondent à des caractéristiques extraites de ces images.

3.2.2 Métriques d'évaluation

Comme métrique de performances, nous avons utilisé l'exactitude, l'information mutuelle normalisée et la pureté :

- Exactitude (ACC) : qui permet de mesurer à quel point les clusters construits ressemblent à ceux de la réalité, en évaluant la correspondance maximale entre elles.

$$ACC(X, Y) = \max_{alloc \in P} \frac{1}{n} \sum_{i=1}^n 1(alloc(Y_i) = X_i) \quad (3.1)$$

avec n le nombre d'observations, P étant l'ensemble des allocations possibles des clusters du regroupement X aux clusters du regroupement Y .

- Information mutuelle normalisée (NMI) : qui permet de mesurer la quantité d'informations partagées entre les clusters construits et les clusters réels.

$$NMI(X, Y) = \frac{\sum_{k=1}^{K^{(X)}} \sum_{k'=1}^{K^{(Y)}} n_{k,k'} \log \left(\frac{N \times n_{k,k'}}{n_k^{(X)} n_{k'}^{(Y)}} \right)}{\sqrt{\left(\sum_{k=1}^{K^{(X)}} n_k^{(X)} \log \left(\frac{n_k^{(X)}}{N} \right) \right) \left(\sum_{k'=1}^{K^{(Y)}} n_{k'}^{(Y)} \log \left(\frac{n_{k'}^{(Y)}}{N} \right) \right)}} \quad (3.2)$$

avec $n_k^{(X)}$ étant le nombre d'observations contenues dans le cluster k du regroupement X , $n_{k'}^{(Y)}$ étant le nombre d'observations contenues dans le cluster k' du regroupement Y , $n_{k,k'}$ étant le nombre d'observations étant dans les clusters k et k' , $K^{(X)}$ étant le nombre de clusters du regroupement X , $K^{(Y)}$ étant le nombre de clusters du regroupement Y .

- Pureté (PUR) : qui permet de mesurer le degré d'homogénéité des clusters construits par rapport aux groupes réels, en pénalisant les potentiels bruits dans ces clusters construits.

$$PUR(X, Y) = \frac{\sum_{y \in Y'} (\max_{x \in X'} \text{card}(\{i | X_i = x, Y_i = y, i \in 1..n\}))}{n} \quad (3.3)$$

avec X' et Y' étant les ensembles des clusters des regroupements X et Y respectivement

3.2.3 Protocole expérimentale

Pour mener à bien les expérimentations, nous avons utilisé un ordinateur portable ayant les caractéristiques suivantes :

- 8 CPUs (2.4Ghz de fréquence chacun)
- 12 Go de mémoire

Nous avons utilisé le langage de programmation python avec comme librairies utiles :

- numpy : pour réaliser les calculs vectoriels
- qpsolvers : pour résoudre les problèmes d'optimisation quadratiques liés à MCLES
- ClusterEnsembles : pour utiliser les algorithmes d'ensemble de clustering

Nous avons également exécuté chaque modèle sujet à l'expérimentation 10 fois de suite. Ce qui nous a conduit à calculer la moyenne et l'écart des performances obtenues pour avoir les performances définitives.

3.2.4 Résultats

Pour observer le comportement des performances de la méthode proposée selon le pourcentage d'observations utilisé pour les échantillons (p) et le nombre de weak-learners utilisés (nw), nous avons fixé une grille d'exploration avec le pourcentage p allant de 50% à 90% avec des pas de 5% et le nombre nw allant de 40 à 160 avec des pas de 40.

Avec MCLES en weak-learner, on remarque que le graphe de l'exactitude (voir la Figure 3.3a) par rapport à tous les paramètres, présente une courbe parabolique dépendante principalement de la taille des échantillons p , où la zone de meilleures valeurs est décrite par des valeurs de p comprises entre 65% à 80%, et des valeurs de nw de plus de 100. On y observe une légère hausse d'exactitude pour p allant de 50% à 80%, puis d'une forte baisse pour p à plus de 80% quelque soit les valeurs de nw (Voir également la Figure 3.3b). On remarque plus précisément sur la Figure 3.3c qu'on a une tendance de légère hausse par rapport à nw avec de meilleures valeurs quand p est compris entre 60% et 80%. Tout ceci nous permet d'affirmer que l'exactitude du modèle dépend plus fortement de la taille des échantillons que du nombre de weak-learners utilisés.

Pour le graphe de l'information mutuelle normalisée présente sur la Figure 3.4a, on remarque que plus la taille p des échantillons utilisés augmente, plus l'information mutuelle normalisée augmente aussi. De plus, l'augmentation de nw conduit également à une légère hausse de cette même information mutuelle. On retrouve cette augmentation par rapport à p sur la Figure 3.4b quelque soit le nombre nw de weak-learners utilisés. On remarque également comme pour l'exactitude une légère hausse de l'information mutuelle normalisée par rapport à nw (voir la Figure 3.4c), avec de meilleures valeurs quand p est compris entre 70% et 80%. Ce qui nous montre qu'on a une corrélation positive entre l'information mutuelle et les deux paramètres, qui est plus forte avec la taille des échantillons.

Pour la pureté, on observe sur son graphe de Figure 3.5a une courbe parabolique dépendant principalement de la taille des échantillons p comme pour le cas de l'exactitude, avec la zone de meilleures valeurs étant décrite par des valeurs de p comprises entre 65% à 75%, et des valeurs du nombre nw de weak-learners de plus de 80. On revoit sur la Figure 3.5b la parabole du graphe précédent, où on observe plus clairement une augmentation générale de la pureté par rapport à p de 50% à 80% puis d'une forte baisse de 80% à plus, quelque soit les valeurs de nw . De plus,




FIGURE 3.3 – Graphes de l'exactitude pour l'approche de type Bagging avec MCLES




FIGURE 3.4 – Graphes de l'information mutuelle normalisée pour la méthode de type Bagging avec MCLES




FIGURE 3.5 – Graphes de la pureté pour la méthode de type Bagging avec MCLES

on retrouve comme pour les autres métriques, une faible augmentation générale de la pureté par rapport à nw , avec de meilleures valeurs quand p est compris entre 70% à 80% (voir la Figure 3.5c). De là, on remarque encore une dépendance visible de la pureté par rapport à la taille des échantillons.

On peut donc conclure que plus on augmente la taille des échantillons, plus on augmente les informations communes entre les clusters construits et les groupes réels. Néanmoins elle doit être ni trop grande ni trop petite pour obtenir des clusters plus homogènes correspondant de mieux en mieux à ceux de la réalité. De façon générale, l'augmentation du nombre de weak-learners permet d'améliorer bien que légèrement la qualité des clusters construits. On retrouve ainsi qu'il est favorable d'utiliser **70% à 80%** des observations pour construire les échantillons et **le plus possible** de weak-learners dans le cas où on a MCLES en weak-learner. Les Tableaux 3.1, 3.2, 3.3 permettent également d'appuyer nos observations.

TABLE 3.1 – Tableau croisé de l'exactitude pour la méthode de type Bagging avec MCLES

nw	40	80	120	160
p				
50%	0.7833	0.7952	0.7952	0.7847
55%	0.7814	0.7890	0.8023	0.7852
60%	0.7757	0.8052	0.7933	0.7947
65%	0.7928	0.7909	0.7947	0.8052
70%	0.8019	0.7904	0.8052	0.8028
75%	0.7942	0.8066	0.7976	0.7952
80%	0.7861	0.7928	0.7919	0.7990
85%	0.7690	0.7833	0.7838	0.7842
90%	0.7780	0.7704	0.7723	0.7809

Avec MVGL en weak-learner, on remarque que le graphe de l'exactitude de Figure 3.6a, présente une courbe parabolique dépendante principalement de la taille p des échantillons utilisés. On y trouve les meilleures valeurs d'exactitude quand p est compris entre 50% à 55% et le nombre nw de weak-learners dépasse 120. Comme sur la Figure 3.6b, on observe également une forte baisse d'exactitude pour p allant de 50% à 70%, puis d'une hausse pour p de plus de 70%, quel que soit le nombre nw de weak-learner. On remarque une forte hausse d'exactitude par rapport à nw quand

TABLE 3.2 – Tableau croisé de l’information mutuelle normalisée pour la méthode de type Bagging avec MCLES

nw	40	80	120	160
p				
50%	0.7195	0.7233	0.7279	0.7245
55%	0.7254	0.7254	0.7325	0.7220
60%	0.7260	0.7417	0.7340	0.7333
65%	0.7374	0.7396	0.7362	0.7445
70%	0.7433	0.7462	0.7465	0.7448
75%	0.7432	0.7525	0.7483	0.7493
80%	0.7425	0.7526	0.7498	0.7545
85%	0.7350	0.7463	0.7452	0.7480
90%	0.7479	0.7411	0.7432	0.7533

TABLE 3.3 – Tableau croisé de la pureté pour la méthode de type Bagging avec MCLES

nw	40	80	120	160
p				
50%	0.7895	0.7976	0.7985	0.7942
55%	0.7957	0.7947	0.8028	0.7914
60%	0.7890	0.8085	0.8009	0.8047
65%	0.8038	0.8033	0.8028	0.8100
70%	0.8057	0.8066	0.8133	0.8123
75%	0.8028	0.8152	0.8071	0.8076
80%	0.8033	0.8090	0.8061	0.8133
85%	0.7923	0.8014	0.8014	0.8014
90%	0.7995	0.7933	0.7952	0.8014

p est compris entre 50% et 55%, mais une tendance plus légère pour des valeurs de p de plus de 55% (Voir également la Figure 3.6c). Nous pouvons donc affirmer que l’exactitude dépend plus fortement de la taille des échantillons que du nombre de weak-learners.

Pour le graphe de l’information mutuelle normalisée, visible sur la Figure 3.7a, plus la taille des échantillons augmente, plus cette information mutuelle diminue. L’augmentation du nombre nw de weak-learners présente une légère hausse de l’information mutuelle normalisée. On retrouve aussi sur la Figure 3.7b cette corrélation entre p et l’information mutuelle normalisée quelque soit les valeurs de nw . On remarque également avec plus de précision sur la Figure 3.7c que l’augmentation de nw conduit généralement à une légère hausse de l’information mutuelle, mais qui devient plus forte pour des valeurs de p comprises entre 50% et 55%. Cela montre que l’information mutuelle dépend négativement de la taille des échantillons et positivement du nombre de weak-learners utilisés.

Pour la pureté, son graphe de Figure 3.8a montre que plus la taille p des échantillons augmente, plus la pureté augmente. On peut également y voir que l’augmentation du nombre nw de weak-learners conduit à une hausse plus légère de pureté. On revoit également ces faits sur la Figure 3.8b, où l’augmentation générale de la pureté qui devient plus forte lorsque p est supérieur à 80% quelque soit le nombre de weak-learners. On retrouve aussi sur la Figure 3.5c une hausse légère




FIGURE 3.6 – Graphes de l'exactitude pour la méthode de type Bagging avec MVGL




FIGURE 3.7 – Graphes de l'information mutuelle normalisée pour la méthode de type Bagging avec MVGL




FIGURE 3.8 – Graphes de la pureté pour la méthode de type Bagging avec MVGL

de performance par rapport à nw , avec de meilleures valeurs quand p est à plus de 85%. On peut donc affirmer qu'on a une corrélation positive entre la pureté et les paramètres, qui est plus forte avec la taille des échantillons.

Nous pouvons ainsi conclure que plus on augmente la taille des échantillons, plus on a tendance à avoir des clusters plus homogènes, mais qui correspondent moins aux groupes réels avec une réduction de la quantité d'informations communes. Ce qui nous amène à voir que nous avons une corrélation négative entre la pureté et l'information mutuelle normalisée. On retrouve ainsi grâce à ces observations qu'il est favorable d'utiliser 50% à 55% des observations pour construire des échantillons et le plus possible de weak-learners dans le cas où MVGL est en weak-learner. Les Tableaux de performances 3.4, 3.5 et 3.6 permettent d'appuyer nos observations.

TABLE 3.4 – Tableau croisé de l'exactitude pour la méthode de type Bagging avec MVGL

nw	40	80	120	160
p				
50%	0.5852	0.5933	0.6080	0.6142
55%	0.5742	0.6095	0.6085	0.6180
60%	0.5761	0.5809	0.5957	0.5780
65%	0.5809	0.5961	0.5795	0.5785
70%	0.5814	0.5738	0.5752	0.5804
75%	0.5757	0.5804	0.5752	0.5780
80%	0.5785	0.5795	0.5809	0.5842
85%	0.5942	0.5890	0.5838	0.5861
90%	0.6014	0.5966	0.6038	0.5990

Grâce à ces recommandations sur les paramètres, nous avons défini leurs valeurs par défaut par rapport au type de weak-learner (voir le Tableau 3.7). On remarque en utilisant les tableaux de performances que 55% des observations pour la construction des échantillons conduisent généralement à de meilleures valeurs pour le cas de MVGL. Dans le cas de MCLES on retrouve plutôt 70% des observations.

Pour mettre en lumière les corrélations qu'on observe entre les métriques d'évaluation, nous avons calculé les coefficients de corrélation entre elles, qui sont visibles sous forme de grilles colorées présentées sur les Figures 3.9b et 3.9a. Pour MCLES, on observe sur la Figure 3.9a qu'on a une

TABLE 3.5 – Tableau croisé de l’information mutuelle normalisée pour la méthode de type Bagging avec MVGL

nw	40	80	120	160
p				
50%	0.6084	0.6204	0.6461	0.6560
55%	0.6098	0.6496	0.6611	0.6566
60%	0.6229	0.6428	0.6384	0.6382
65%	0.6275	0.6385	0.6335	0.6306
70%	0.6256	0.6254	0.6201	0.6274
75%	0.6109	0.6262	0.6254	0.6273
80%	0.6261	0.6222	0.6231	0.6192
85%	0.6051	0.6149	0.6144	0.6069
90%	0.5962	0.6013	0.5977	0.5961

TABLE 3.6 – Tableau croisé de la pureté pour la méthode de type Bagging avec MVGL

nw	40	80	120	160
p				
50%	0.6066	0.6019	0.6171	0.6228
55%	0.6019	0.6290	0.6300	0.6252
60%	0.6200	0.6266	0.6290	0.6290
65%	0.6295	0.6357	0.6309	0.6295
70%	0.6323	0.6319	0.6261	0.6385
75%	0.6314	0.6371	0.6323	0.6352
80%	0.6357	0.6366	0.6380	0.6423
85%	0.6519	0.6466	0.6414	0.6433
90%	0.6585	0.6538	0.6609	0.6561

TABLE 3.7 – Tableau des valeurs par défaut des paramètres de la méthode de type Bagging

	p	nw
Bagging avec MCLES	70%	160
Bagging avec MVGL	55%	160

faible corrélation entre l’information mutuelle normalisée et l’exactitude, une corrélation relativement bonne entre la pureté et l’information mutuelle normalisée, et une bonne corrélation entre l’exactitude et la pureté. Ce qui permet d’affirmer qu’il n’y a que des corrélations possibles entre métriques dans ce cas. Pour MVGL, on observe plutôt sur la Figure 3.9b qu’on a une faible corrélation négative entre la pureté et l’information mutuelle normalisée, une faible corrélation positive entre la pureté et l’exactitude et une faible corrélation positive entre l’exactitude et l’information mutuelle normalisée. Ce qui permet montre qu’il n’y a pas dans ce cas de forte corrélation entre les métriques.

Ces valeurs de paramètres visibles au Tableau 3.7 ont été utilisées pour la réalisation des expérimentations dont les résultats sont sur le Tableau 3.8.




FIGURE 3.9 – Corrélations entre métriques pour la méthode de type Bagging

TABLE 3.8 – Tableau de comparaison des performances

	ACC	NMI	PUR
model			
MVGL	0.600±0	0.595±0	0.657±0
Bagging avec MVGL	0.615±0.036	0.643±0.029	0.623±0.020
MCLES	0.720±0.058	0.718±0.033	0.755±0.047
Bagging avec MCLES	0.801±0.022	0.743±0.014	0.811±0.014

CHAPITRE 4

CONCLUSION GÉNÉRALE

Dans cette étude, nous avons considéré la complémentarité et le potentiel consensus d'informations qui existent entre les spectres MS et RMN des molécules. Cela dans le but d'identifier les molécules qui ne le sont pas et donc d'identifier les réseaux moléculaires les contenant. Les méthodes existantes telles que GNPS et MADByTE utilisant respectivement les spectres MS et RMN, ne prennent pas en compte cette complémentarité et ce consensus d'informations obtenus des molécules par spectrométrie. Pour pouvoir les exploiter pour la construction des réseaux issus respectivement de GNPS et de MADByTE, nous avons combiné les clusters dans ces réseaux avec ceux obtenus par le biais des algorithmes de clustering multi-vues MCLES ou MVGL, par apprentissages par ensemble Bagging et Boosting, avec comme algorithme de vote majoritaire MCLA. Pour obtenir automatiquement les clusters contenus dans les réseaux, nous avons utilisé l'algorithme DBSCAN en définissant le voisinage d'une molécule dans un réseau moléculaire.

Nos expérimentations sur la dataset MSRC-V1, ont permis d'observer qu'avec MCLES comme weak-learner, nous avons les meilleures performances en termes de regroupement. On parle de 80.1% d'exactitude, 74.3% d'information mutuelle normalisée et de 81.1% de pureté pour le Bagging. Cela montre que les clusters construits par apprentissage ensembliste tiennent mieux compte des structures complexes des données. Ce qui nous permet d'affirmer que l'approche basée sur les apprentissages Bagging et Boosting améliorent la qualité des réseaux moléculaires qui accélèrent leurs processus d'identification.

Néanmoins, nous avons été confrontés à des difficultés qui nous ont permis de cerner des limites à l'approche. Premièrement toutes les approches proposées ont besoin de données complètes des spectres MS et RMN qui se trouvent très difficile à avoir en pratique, ensuite le temps d'exécution est relativement grand et enfin les approches proposées accordent la même importance aux données de chaque représentation malgré le fait que les spectres MS contiennent beaucoup plus de bruits que les spectres RMN. De là, nous comptons pour la suite, en premier lieu expérimenter les approches proposées complètement sur des spectres de molécules issus de notre propre collecte des données, puis d'accélérer les approches par parallélisation, et d'enfin proposer une méthode prenant en compte l'importance que doit avoir les spectres MS et RMN chacune dans la construction d'une représentation unifiée pour améliorer le clustering.

BIBLIOGRAPHIE

- [1] Mingxun Wang, Jeremy J Carver, Vanessa V Phelan, Laura M Sanchez, Neha Garg, Yao Peng, Don Duy Nguyen, Jeramie Watrous, Clifford A Kapon, Tal Luzzatto-Knaan, et al. Sharing and community curation of mass spectrometry data with global natural products social molecular networking. *Nature biotechnology*, 34(8) :828–837, 2016.
- [2] Man-Sheng Chen, Jia-Qi Lin, Xiang-Long Li, Bao-Yu Liu, Chang-Dong Wang, Dong Huang, and Jian-Huang Lai. Representation learning in multi-view clustering : A literature review. *Data Science and Engineering*, 7(3) :225–241, 2022.
- [3] Yan Yang and Hao Wang. Multi-view clustering : A survey. *Big Data Mining and Analytics*, 1(2) :83–107, 2018.
- [4] Kun Zhan, Changqing Zhang, Junpeng Guan, and Junsheng Wang. Graph learning for multiview clustering. *IEEE transactions on cybernetics*, 48(10) :2887–2895, 2017.
- [5] Tahani Alqurashi and Wenjia Wang. Clustering ensemble method. *International Journal of Machine Learning and Cybernetics*, 10 :1227–1246, 2019.
- [6] FI Saldívar-González, VD Aldas-Bulos, JL Medina-Franco, and F Plisson. Natural product drug discovery in the artificial intelligence era. *Chemical Science*, 13(6) :1526–1546, 2022.
- [7] Michael Wenk, Jean-Marc Nuzillard, and Christoph Steinbeck. Sherlock—a free and open-source system for the computer-assisted structure elucidation of organic compounds from nmr data. *Molecules*, 28(3) :1448, 2023.
- [8] Adriano Rutz, Maria Sorokina, Jakub Galgonek, Daniel Mietchen, Egon Willighagen, Arnaud Gaudry, James G Graham, Ralf Stephan, Roderic Page, Jiří Vondrášek, et al. The lotus initiative for open natural products research : knowledge management through wikidata. *BioRxiv*, pages 2021–02, 2021.
- [9] Arnaud Gaudry, Marco Pagni, Florence Mehl, Sébastien Moretti, Luis-Manuel Quiros-Guerrero, Adriano Rutz, Marcel Kaiser, Laurence Marcourt, Emerson Ferreira Queiroz, Jean-Robert Ioset, et al. A sample-centric and knowledge-driven computational framework for natural products drug discovery. 2023.

- [10] Joseph M Egan, Jeffrey A van Santen, Dennis Y Liu, and Roger G Linington. Development of an nmr-based platform for the direct structural annotation of complex natural products mixtures. *Journal of natural products*, 84(4) :1044–1055, 2021.
- [11] Mélissa Nothias, Louis-Félix exand Nothias-Esposito, Ricardo Da Silva, Mingxun Wang, Ivan Protsyuk, Zheng Zhang, Abi Sarvepalli, Pieter Leyssen, David Touboul, Jean Costa, et al. Bioactivity-based molecular networking for the discovery of drug leads in natural product bioassay-guided fractionation. *Journal of natural products*, 81(4) :758–767, 2018.
- [12] Marie-Claude Menet. Principes de la spectrométrie de masse. *Revue francophone des laboratoires*, 2011(437) :41–53, 2011.
- [13] Panthadeep Bhattacharjee and Pinaki Mitra. A survey of density based clustering algorithms. *Frontiers of Computer Science*, 15 :1–27, 2021.
- [14] Hiroaki Shiokawa, Tomokatsu Takahashi, and Hiroyuki Kitagawa. Scalesscan : scalable density-based graph clustering. In *Database and Expert Systems Applications : 29th International Conference, DEXA 2018, Regensburg, Germany, September 3–6, 2018, Proceedings, Part I 29*, pages 18–34. Springer, 2018.
- [15] Tianfu Wang, Chang Ren, Yun Luo, and Jing Tian. Ns-dbscan : A density-based clustering algorithm in network space. *ISPRS International Journal of Geo-Information*, 8(5) :218, 2019.
- [16] Sanjoy Dasgupta, Michael Littman, and David McAllester. Pac generalization bounds for co-training. *Advances in neural information processing systems*, 14, 2001.
- [17] Steffen Bickel and Tobias Scheffer. Multi-view clustering. In *ICDM*, volume 4, pages 19–26. Citeseer, 2004.
- [18] Huang L.-Wang C.-D. Huang D. Chen, M.-S. Multi-view clustering in latent embedding space. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2020.
- [19] Yasi Wang, Hongxun Yao, and Sicheng Zhao. Auto-encoder based dimensionality reduction. *Neurocomputing*, 184 :232–242, 2016.
- [20] Sandrine Dudoit and Jane Fridlyand. Bagging to improve the accuracy of a clustering procedure. *Bioinformatics*, 19(9) :1090–1099, 2003.
- [21] Alexander Strehl and Joydeep Ghosh. Cluster ensembles—a knowledge reuse framework for combining multiple partitions. *Journal of machine learning research*, 3(Dec) :583–617, 2002.
- [22] Aristides Gionis, Heikki Mannila, and Panayiotis Tsaparas. Clustering aggregation. *Acm transactions on knowledge discovery from data (tkdd)*, 1(1) :4–es, 2007.